Entstanden an der

Hochschule Niederrhein
University of Applied Sciences

Ingenieurwissenschaften und Informatik
Faculty of Engineering and Computer Science

Bachelorarbeit

zur Erlangung

des akademischen Grades

Bachelor of Engineering (B. Eng.)

Aufbau und Validierung einer automatisierten Mikrofonarray-Aufnahmeplattform für eine Mehrkanal-Sprachdatenbank

angefertigt im

Fachbereich Ingenieurwissenschaften und Informatik

Hochschule Niederrhein

vorgelegt von

Yuxuan Li

Matr.-Nr.: 1803550

Studiengang: Mechatronik

Betreuender Professor: Prof. Dr. Edwin Naroska

Zweitprüfer: Lukas Cramer

Krefeld, im August 2026

Zusammenfassung

Serviceroboter werden im Dienstleistungssektor zunehmend weit verbreitet eingesetzt. Die Zuverlässigkeit ihrer Spracherkennung in Mensch-Roboter-Dialogen ist zu einem wichtigen Forschungsthema geworden. Bei der Spracherkennung müssen Roboter die aufgenommenen Sprachsignale in der Regel zunächst einer Schallquellenfilterung unterziehen, um Umgebungsgeräusche und störende Stimmen zu unterdrücken. Derzeit werden häufig Mikrofonarrays zur Sprachaufnahme eingesetzt. Anschließend erfolgt die Schallquellenfilterung mithilfe von Beamforming-Algorithmen. Das Problem besteht darin, dass das Training von Modellen für deep-learning-basierte Beamforming-Algorithmen relativ hohe Anforderungen an das Trainingsmaterial stellt. Häufig müssen die Schallquellen im Trainingsmaterial aus verschiedenen Positionen stammen, und der Winkel der Schallquelle relativ zum Aufnahmemikrofon muss bekannt sein. Sprachdatenbanken, die für die Schallquellenfilterung bei Servicerobotern geeignet sind und Sprachsignale von Schallquellen aus verschiedenen Positionen enthalten, sind derzeit jedoch relativ selten. Um dieses Problem zu lösen, beschreibt diese Arbeit den Aufbau einer automatisierten Plattform zur Erfassung einer Sprachdatenbank, die für die Schallquellenfilterung bei Servicerobotern geeignet ist und das Deep-Learning-Training unterstützt. Nach dem Aufbau der Plattform wurden in diesem Experiment insgesamt 1.200 Trainingsaudiodateien und 240 Referenzaudiodateien aufgenommen und zu einer Sprachdatenbank zusammengestellt. Außerdem werden erste Ergebnisse der Beamforming-Evaluierung als Referenz für weitere Arbeiten bereitgestellt.

Abstract

Service robots are increasingly being widely used in the service sector, and the reliability of their speech recognition in human-robot dialogue scenarios has become a popular research topic. For speech recognition, robots usually need to perform sound source filtering on the recorded speech first in order to suppress environmental noise and interfering speech. At present, microphone arrays are commonly used as speech recording tools, and sound source filtering is then performed using beamforming algorithms. The problem is that the model training of deep-learning-based beamforming algorithms has relatively strict requirements for the training material. The sound sources in the material often need to come from different positions, and the angle of the sound source relative to the recording microphone needs to be known. However, speech databases that are suitable for sound source filtering scenarios involving service robots and contain sound sources from different positions are currently relatively rare. To solve this problem, this paper describes how to build an automated speech database recording platform that is suitable for sound source filtering scenarios involving service robots and supports deep learning training. After the platform was completed, a total of 1,200 training audio recordings and 240 reference audio recordings were collected in this experiment to form a speech database. Preliminary beamforming evaluation results are also provided for future reference.

Eidesstattliche Erklärung

KI Disclaimer:

In dieser wissenschaftlichen Arbeit wurden Künstliche-Intelligenz (KI)-Technologien insbesondere Sprachmodelle zur Unterstützung verschiedener Aspekte der Forschung eingesetzt. Diese Anwendungen umfassen die Übersetzung und sprachliche Überarbeitung einzelner Textabschnitte, die Optimierung der Visualisierung statistischer Ergebnisse sowie die lokale Bereitstellung der Algorithmen und dessen Integration in die Verarbeitungspipeline. Es wird ausdrücklich darauf hingewiesen, dass die endgültige Verantwortung für die inhaltliche Richtigkeit, die kritische Reflexion und die Interpretation der Ergebnisse beim Autor/der Autorin dieser Arbeit liegt. Die KI diente lediglich als Werkzeug und nicht als Ersatz für die kritische und analytische Argumentation des Forschenden.

Name: Yuxuan Li

Matrikelnr .: 1803550

Titel: Aufbau und Validierung einer automatisierten Mikrofonarray-Aufnahmeplattform für eine Mehrkanal-Sprachdatenbank

Ich versichere durch meine Unterschrift, dass die vorliegende Arbeit ausschließlich von mir verfasst wurde. Es wurden keine anderen als die von mir angegebenen Quellen und Hilfsmittel benutzt.

Krefeld, 24.08.2026 — Yuxuan Li Yuxuan Li

Ort, Datum — Unterschrift

Inhalt

1 Einleitung 9

1.1 Hintergrund des Themas 9

1.2 Praktische Probleme 10

1.3 Forschungsinhalt und Ziele 13

2 Theoretischer Hintergrund und frühere Forschung 16

2.1 Mikrofonarray 16

2.2 Prinzip des Beamformings und einige Algorithmen 17

2.2.1 Delay-and-Sum-Beamforming 17

2.2.2 Schallquellenlokalisierung auf Grundlage von Deep Learning 18

2.3 Akustische Bewertungskennwerte 19

2.3.1 Signal-Rausch-Verhältnis 19

2.3.2 Short-Time Objective Intelligibility 20

2.3.3 Perceptual Evaluation of Speech Quality 21

2.4 Frühere Forschung 22

2.5 Zusammenfassung des Kapitels 22

3 Anforderungsanalyse und Vergleich der Lösungskonzepte 24

3.1 Analyse der Aufgabenanforderungen 24

3.2 Analyse der Anforderungen an das mechanische System 24

3.3 Analyse der Anforderungen an das Steuerungssystem 26

3.4 Analyse der Anforderungen an die Sprachdatenbank 27

3.5 Vergleich der Konzepte und endgültig ausgewähltes Konzept 27
3.6 Zusammenfassung des Kapitels 29
4 Entwurf und Aufbau des mechanischen Systems 30
4.1 Gesamtentwurf 30
4.2 Entwurf der Verbindungsteile für den Schwenkarmantrieb 30
4.3 Entwurf der Schwenkarmstruktur 33
4.4 Entwurf des Lautsprecherwagens 34
4.5 Entwurf der Steuerstruktur des Mikrofonarrays 36
4.6 Entwurf der Befestigungsstruktur des Mikrofonarrays 37
4.7 Praktische Montage und Anpassung 39
4.8 Zusammenfassung des Kapitels 42
5 Entwurf des Elektronik- und Steuerungssystems 43
5.1 Gesamtsteuerung und Ablauf 43
5.2 Stromversorgung 44
5.3 Kabelanforderungen und Kabelführung 44
5.4 Steuerung des Mikrofonarrays 45
5.5 Steuerung der Lautsprecherwagen 47
5.6 Aufnahmekonfiguration und -steuerung 48
5.7 Zusammenfassung des Kapitels 50
6 Vorbereitung und Ablauf der Datenerfassung 51
6.1 Herkunft und Auswahl des Audiomaterials 51
6.2 Entwurf der Sprachdatenbank 52

6.2.1 Entwurf der Gesamtstruktur 52
6.2.2 Entwurf der enthaltenen Dateien 53
6.3 Verbesserungen nach Aufnahmetests und endgültiger Steuerungscode 54
6.3.1 Speicherung der Aufnahmen 54
6.3.2 Vorbereitung vor der ersten Aufnahme 55
6.3.3 Wiedergabepufferzeit 55
6.4 Erste Bewertung der Aufnahmeergebnisse 56
6.5 Zusammenfassung des Kapitels 56
7 Praktische Verwendung und Bewertung der Sprachdatenbank 57
7.1 Auswahl und kurze Beschreibung des Testalgorithmus 57
7.2 Konfiguration von JNF-SSF und Vorverarbeitung der Audiodatenbank. 57
7.2.1 Definition der Richtungslabels 57
7.2.2 Ausrichtung der Audiodaten mit und ohne Störgeräusch 58
7.2.3 Vorverarbeitung der Audiosignale 58
7.2.4 Trainingseinstellungen von JNF-SSF 59
7.3 Trainings- und Bewertungsergebnisse 60
7.3.1 Bewertung der Qualität der aufgenommenen Audiodaten 60
7.3.2 Bewertung der Qualität der mit DAS verbesserten Audiodaten 61
7.3.3 Bewertung der Qualität der mit JNF-SSF verbesserten Audiodaten 62
7.3.4 Bewertung der Qualität der durch das kreuzvalidiert trainierte

Modell verbesserten Audiodaten 64
7.4 Zusammenfassung des Kapitels 66
8 Diskussion der Versuchsergebnisse 67
8.1 Erklärung der Versuchsergebnisse 67
8.2 Fehleranalyse 68
8.2.1 Fehlerquellen 68
8.2.2 Möglichkeiten für spätere Verbesserungen 70
9 Zusammenfassung und Ausblick 72
9.1 Zusammenfassung der Versuchsarbeiten 72
9.2 Beitrag des Versuchs 72
9.3 Grenzen des Versuchs und mögliche Verbesserungen 72
Literaturverzeichnis 74
Anhang 77

1 Einleitung

1.1 Hintergrund des Themas

Serviceroboter sind ein neues Schwerpunktthema im Dienstleistungssektor. Xu et al. stellen fest, dass die jährliche Wachstumsrate von Servicerobotern in Hotels im Jahr 2021 bei 25,5 % lag. Es wird erwartet, dass Roboter bis 2030 25 % der Arbeitsplätze im Hotel- und Tourismussektor einnehmen werden; im Jahr 2027 wird der gesamte Marktwert von Servicerobotern 40 Milliarden US-Dollar erreichen [1]. Besonders nach der COVID-19-Pandemie ist der Bedarf an interaktiven Dienstleistungen zwischen Menschen und Maschine stark gestiegen, und auch ihre Verbreitung nimmt schnell zu. Serviceroboter übernehmen nicht nur mehr Arbeitsplätze, sondern werden auch von der Öffentlichkeit anerkannt: In Restaurants erhalten Roboter mit hoher Serviceeffizienz allgemein Anerkennung und positive Bewertungen (El-Said et al.) [2]. Diese Daten zeigen deutlich die praktische Bedeutung und Notwendigkeit weiterer Forschung zu Servicerobotern.

Unter den verschiedenen Funktionen von Servicerobotern nimmt die Interaktionsfähigkeit seit jeher eine wichtige Stellung ein. Beispiele sind die Eingabe von Befehlen über eine interaktive Oberfläche, die Bestimmung der Position einer interagierenden Person oder eines Interaktionsziels durch visuelle Verfahren sowie Dialoge und die Annahme von Befehlen über einen Audioeingang. Der vollständige Ablauf vom Audioeingang bis zur entsprechenden Aktionsausgabe besteht aus vier Schritten: Audio erfassen – Audio erkennen und verarbeiten – Ausgabeinhalt bestimmen – Aktion ausgeben. Die ersten beiden Schritte beruhen hauptsächlich auf Mikrofonen und den zugehörigen Audiogeräten, zum Beispiel Soundkarten sowie Geräten zur Audiocodierung und -decodierung. Ihre Hauptaufgabe besteht darin, das aufgenommene Audio in Inhalte umzuwandeln, die ein Computer verstehen kann. Bei Servicerobotern besteht die Aufgabe dieser beiden Schritte vor allem darin, die aufgenommenen Sprachaufnahmen in den entsprechenden Text umzuwandeln, damit

die nachfolgenden Programme den Inhalt verstehen können. Das ursprünglich aufgenommene Audio kann jedoch häufig nicht direkt mit einem Sprache-zu-Text-Erkennungsalgorithmus umgewandelt werden, weil seine Audioqualität durch verschiedene Faktoren meist nicht hoch ist und deshalb eine weitere Audioverarbeitung benötigt wird.

1.2 Praktische Probleme

Im Bereich der Mensch-Roboter-Kommunikation steht der Audioeingang seit jeher vor den folgenden Problemen:

(1) Schallquellenerkennung: Die Arbeitsumgebung eines Serviceroboters ist häufig sehr komplex. Es können mehrere Sprachquellen aus einem Bereich von 360° vorhanden sein, und ihre Positionen sind häufig unterschiedlich oder sogar in Bewegung. Der Roboter soll erkennen, welche Sprachquelle mit ihm spricht, und eine bestimmte Reaktion ausführen, zum Beispiel den Kopf zur sprechenden Person drehen.

(2) Schallquellenfilterung: In einer komplexen Umgebung gibt es laute Hintergrundgeräusche, Arbeitsgeräusche der Maschine selbst, Stimmen mehrerer sprechender Personen sowie Echos aller Geräusche in einem begrenzten Raum. Der Serviceroboter soll darin die Zielschallquelle erkennen, diese verstärken und die Lautstärke der anderen Schallquellen verringern, um Störungen auszuschließen.

(3) Spracherkennung: Der Roboter soll den Sprachinhalt genau erkennen und transkribieren und anhand dieses Inhalts die entsprechenden Befehle ausführen. Das Erkennungsergebnis hängt sowohl von der Software zur Sprachtranskription als auch vom Endergebnis der Schallquellenfilterung ab. Diese drei Probleme bauen häufig schrittweise aufeinander auf. Ob das jeweils vorherige Problem gelöst wurde, wirkt sich direkt auf die Umsetzung des nächsten Problems aus.

Unter diesen drei Problemen ist die Schallquellenfilterung häufig am komplexesten. Zur Lösung dieses Problems haben Forschende viele praktische Methoden vorgeschlagen. Diese Methoden unterscheiden sich im Detail, aber insgesamt erfordern die meisten Lösungen eine Zusammenarbeit von Software und Hardware. Auf der Softwareseite werden heute meistens bestimmte Algorithmen

verwendet, um Schallquellen zu analysieren, zu filtern und zu verstärken. Zuerst werden mit einer Schätzung der Einfallsrichtung (Direction of Arrival) die Anzahl und die Richtungen der Schallquellen ungefähr bestimmt. Anschließend wird Beamforming eingesetzt, um die Schallquelle aus einer bestimmten Richtung zu verstärken und die übrigen Richtungen abzuschwächen. So soll erreicht werden, dass „nur der Schall aus einer Richtung gehört wird“. Die Hardware dient hauptsächlich den Softwarealgorithmen. Für die Schätzung der Einfallsrichtung gelten bestimmte Anforderungen an die Anzahl der Mikrofone: Mit einem einzelnen Aufnahmemikrofon kann eine Schallquelle nicht lokalisiert und erst recht nicht eine bestimmte Schallquelle extrahiert und verstärkt werden. Eine Anordnung mit zwei Mikrofonen ist symmetrisch. Bei der Schätzung einer Schallquelle in einer Ebene lässt sich deshalb nicht bestimmen, auf welcher Seite der beiden Mikrofone sie liegt. Dies wird als Vorne-Hinten-Mehrdeutigkeit bezeichnet (Kim et al.) [3]. Daher sind mindestens drei Mikrofone erforderlich, um die genaue Position einer Schallquelle zu bestimmen. Die heute übliche Aufnahmelösung ist ein Mikrofonarray. Dabei werden mehrere oder sogar mehrere Dutzend Mikrofone direkt auf einer Entwicklungsplatine zusammengeführt, um eine genaue Lokalisierung zu ermöglichen. Vorintegrierte Chips vereinfachen zugleich die Mehrkanalsynchronisation zwischen den Mikrofonen. Der gesamte Ablauf der Schallquellenfilterung mit diesen Techniken lautet somit: Zuerst nimmt ein Mikrofonarray Mehrkanalaudio auf, danach wird die Richtung der Schallquelle durch eine Schätzung der Einfallsrichtung bestimmt, und schließlich wird die Hauptschallquelle durch Beamforming verstärkt.

Gegenwärtig entwickelt sich Beamforming auf Grundlage von Deep Learning zu einem neuen Forschungsschwerpunkt. Die Hauptwirkung traditioneller Beamforming-Algorithmen liegt in der räumlichen Filterung. Die dafür erforderlichen Informationen, etwa die Richtung der Schallquelle, können nur mit einem vorgeschalteten Algorithmus zur Schätzung der Einfallsrichtung bestimmt werden. In manchen Anwendungen, in denen die Richtung der Schallquelle erkannt werden muss, zum Beispiel wenn ein Roboter seinen Kopf zur sprechenden Person dreht, kann traditionelles Beamforming

die Aufgabe nicht selbstständig erfüllen. Deep-Learning-Beamforming kann dagegen Sprachdaten mit Positionslabels direkt lernen und anhand dieser Labels die Beziehungen der räumlichen Filterung erfassen. Dadurch kann die Beamforming-Wirkung verbessert werden; einige Algorithmen können sogar direkt die Position einer Schallquelle in unbekanntem Mehrkanalaudio vorhersagen. Da ein durch Deep Learning trainiertes Modell den Zusammenhang zwischen der Position einer Schallquelle und dem Sprachsignal gelernt hat, kann es in der praktischen Anwendung bei bekannter Position der Zielschallquelle, zum Beispiel nach einer vorherigen Bestimmung durch einen Algorithmus, im Vergleich zu traditionellem Beamforming eine bessere Filterwirkung liefern. Deep-Learning-Beamforming ist deshalb ein Algorithmus, der Einfachheit und Wirkung miteinander verbindet.

Für das Problem der Schallquellenfilterung bei Servicerobotern sind Sprachdatenbanken, die die Anforderungen an die Bewertung oder das Training von Deep-Learning-Beamforming-Algorithmen vollständig erfüllen, jedoch sehr selten. Eine geeignete Sprachdatenbank sollte die folgenden Bedingungen erfüllen:

(1) Kombination aus menschlicher Sprachquelle und Hintergrundgeräusch. Die Arbeitsumgebung eines Serviceroboters ist sehr komplex. An einer Hotelrezeption muss der Roboter zum Beispiel möglicherweise unter dem Einfluss der Stimmen mehrerer Gäste und von Hintergrundgeräuschen die Stimme des Gastes erkennen und verstärken, der mit ihm spricht, damit die Sprachumwandlung durchgeführt werden kann.

(2) Schallquellen aus mehreren unterschiedlichen Winkeln. Die Richtungen der vom Serviceroboter empfangenen Schallquellen sind nicht festgelegt. Im Idealfall sollte eine Sprachdatenbank Schallquellen aus allen Richtungen enthalten. Wegen der realen Aufnahmebedingungen und des Zeitaufwands sollte die Sprachdatenbank die Aufnahmewinkel so fein wie möglich unterteilen, zum Beispiel mit einer Aufnahme alle 5°, um Schallquellen aus allen Richtungen zu simulieren.

(3) Berücksichtigung des Raumnachhalls bei der Aufnahme. Wegen der Raumwände erreicht der Schall der Quelle das Mikrofon nicht nur direkt, sondern auch

wiederholt als Nachhall über Reflexionen an den Wänden. Dadurch wird die Bestimmung der Position der Schallquelle gestört. Der Raumnachhall hängt nicht nur von der Raumgröße, sondern auch von der Raumform und sogar von der Ausrichtung des Mikrofons ab. Eine Sprachdatenbank sollte möglichst mehrere Nachhallumgebungen simulieren und so ausreichend Unterstützung für Tests und Training bieten.

(4) Kennzeichnung der Daten. Alle diese räumlichen Informationen sollen zusammen mit dem aufgenommenen Audio als Metadaten gespeichert werden. Wenn die Labels fehlen, kann der Algorithmus diese Informationen nicht wirksam lernen.

Nach der gemeinsamen Betrachtung aller genannten Faktoren stehen gegenwärtig nur sehr wenige geeignete Sprachdatenbanken zur Auswahl. Daher ist der Aufbau einer Plattform zur Aufnahme einer Sprachdatenbank speziell für die Schallquellenfilterung bei Servicerobotern notwendig.

1.3 Forschungsinhalt und Ziele

Ausgehend von dem Problem, dass es nur wenige Deep-Learning-Trainingsdatenbanken für die Schallquellenfilterung bei Servicerobotern gibt, analysiert dieser Versuch, welche Bedingungen eine relativ geeignete Sprachdatenbank erfüllen sollte und welche physikalischen Grenzen und Materialanforderungen beim Aufbau einer Aufnahmeplattform für eine Sprachdatenbank bestehen. Er beschreibt den Aufbau einer Plattform zur Erfassung einer Sprachdatenbank und führt einfache Tests sowie eine praktische Anwendung mit der fertig aufgenommenen Datenbank durch. Die Eigenschaften dieser Erfassungsplattform lassen sich ungefähr in die folgenden Punkte unterteilen:

(1) Mischung aus menschlicher Sprache und Umgebungsgeräusch. Der Audioinhalt dieser Sprachdatenbank enthält jeweils mindestens eine saubere menschliche Stimme als Hauptsignal sowie Umgebungsgeräusch, um den Schall zu simulieren, den ein Roboter in einer realen Umgebung „hört“. Der Sprachteil enthält unterschiedliche Texte und Zeitlängen, um Probleme wie eine kleine Anzahl von Trainingsdaten und Underfitting zu vermeiden. Die Umgebungsgeräusche stammen

möglichst aus Situationen mit häufiger Mensch-Maschine-Kommunikation, zum Beispiel aus Hotellobbys, Restaurants und Besprechungsräumen. Außerdem enthält die Sprachdatenbank saubere menschliche Sprache ohne Störgeräusch als Material für überwachtes Lernen.

(2) Schallquellen und Störgeräuschquellen aus mehreren Winkeln. Diese Datenbank verwendet eine bestimmte mechanische Struktur und Steuerungstechnik, mit der sich die als Wiedergabegeräte verwendeten Lautsprecher frei über einen großen Winkel bewegen können. Dadurch können die Zielsprache und die Störgeräuschquelle aus mehreren unterschiedlichen Winkeln wiedergegeben werden. Dies liefert der Sprachdatenbank mehr Winkelinformationen und entspricht besser der Eigenschaft alltäglicher Anwendungen, dass Schall aus jeder Richtung kommen kann.

(3) Aufnahmen mit unterschiedlichen Nachhallbedingungen. Durch die Bewegung des Aufnahmemikrofons wird die Raumform relativ zum Mikrofon bewegt und dadurch der Nachhall verändert. Diese Datenbank erfasst in demselben Raum Raumbedingungen bei unterschiedlichen Ausrichtungen des Arrays und unterschiedlichen räumlichen Anordnungen.

(4) Verbindung von Aufnahme und Daten. Neben den Aufnahmen speichert die Sprachdatenbank auch genaue Angaben zu jeder Aufnahme. Dazu gehören der zur Zielsprache gehörende Text, Winkel und Positionen der einzelnen Schallquellen relativ zum Mikrofon sowie der Winkel des Mikrofons selbst. Dies erleichtert spätere Vergleiche von Sprachtranskriptionen und Datenanalysen.

Bei der Konstruktion und dem Aufbau der Erfassungsplattform für die Sprachdatenbank müssen Kenntnisse aus der Mechatronik eingesetzt werden, darunter die Konstruktion mechanischer Strukturen, Kraftanalyse, Festigkeitsberechnung, Materialauswahl, Systemmodellierung, 3D-Druck bestimmter Bauteile, Entwurf der Verdrahtung und Kommunikation elektronischer Komponenten sowie Entwurf der automatischen Steuerungslogik und Programmierung ihrer Umsetzung. All diese Punkte wurden in diesem Versuch berücksichtigt und praktisch bearbeitet, um die auftretenden Probleme zu lösen.

Nach Abschluss der Sprachdatenerfassung wurden die Sprachaufnahmen aus der Datenbank außerdem mit einem Beamforming-Algorithmus verarbeitet. Damit wurde untersucht, ob der Algorithmus aus den Aufnahmen mit gemischter Sprache und Störgeräusch erfolgreich die menschliche Sprache extrahieren kann. Akustische Bewertungskennwerte wurden eingesetzt, um die Extraktionswirkung besser zu analysieren. Mit diesen Tests kann geprüft werden, ob die Erfassungsplattform erfolgreich Aufnahmen erstellen und die nachfolgenden Arbeiten wirksam unterstützen kann.

Zusammenfassend lautet das Ziel dieses Versuchs: Aufbau einer automatisierten Erfassungsplattform für eine Sprachdatenbank, die für die Schallquellenfilterung bei Servicerobotern geeignet ist und das Deep-Learning-Training unterstützt, Aufnahme einer ausreichenden Anzahl von Sprachdaten zur Bildung einer Sprachdatenbank sowie Bereitstellung erster Beamforming-Daten als Referenz.

2 Theoretischer Hintergrund und frühere Forschung

2.1 Mikrofonarray

Ein Mikrofonarray besteht aus mehreren Mikrofonen, die an unterschiedlichen räumlichen Positionen angeordnet sind. Durch die Verarbeitung mehrerer Eingangssignale kann das Mikrofonarray Signale aus einer bestimmten Richtung verstärken oder abschwächen. Damit bietet es eine Möglichkeit, ein Zielsignal bei vorhandenen Störgeräuschquellen zu verstärken. Im Folgenden werden das Aufnahmeprinzip eines Mikrofonarrays und seine Anwendung beim Beamforming kurz vorgestellt.

Ein Mikrofonarray ist ein Aufnahmesystem, das aus mehreren Mikrofonen in einer bestimmten räumlichen Anordnung besteht. Im Vergleich zu einem einzelnen Mikrofon zeichnet es nicht nur den Schallinhalt auf, sondern gleichzeitig auch die Unterschiede, die beim Eintreffen des Schalls an den verschiedenen Mikrofonen entstehen. Wegen der unterschiedlichen Positionen der Mikrofone können sich die Ankunftszeit, Phase und Intensität derselben Schallquelle in den einzelnen Kanälen leicht unterscheiden. Diese Unterschiede enthalten räumliche Informationen wie die Richtung und Entfernung der Schallquelle, Störgeräusche aus der Umgebung und Reflexionen der Umgebung (Benesty, Chen) [4]. Aufnahmen eines Mikrofonarrays sind deshalb normalerweise Mehrkanalaudiodaten, weil einkanaliges Audio nur Informationen einer einzelnen Schallquelle darstellen kann und keine Unterschiede der räumlichen Parameter zwischen mehreren Schallquellen zeigt. Bei realen Aufnahmen reagiert ein Mikrofonarray empfindlich auf die Versuchsbedingungen: Die Anzahl der Mikrofone, die Form des Arrays, der Mikrofonabstand, die Abtastrate, der Winkel der Schallquelle und die Raumumgebung beeinflussen das Aufnahmeergebnis. Eine Schallquelle im Fernfeld erreicht die Mikrofone zum Beispiel anders als eine Schallquelle im Nahfeld; in einem Raum verändern Nachhall und Reflexionen ebenfalls die Beziehungen zwischen den Kanälen (McCowan) [5]. Wenn Daten eines Mikrofonarrays für einen

Algorithmustest verwendet werden sollen, müssen daher gewöhnlich Metadaten wie die Position der Schallquelle, die Ausrichtung des Mikrofonarrays, die Entfernung der Schallquelle, der wiedergegebene Inhalt und die Geräuschbedingungen aufgezeichnet werden. Andernfalls lässt sich auch bei vorhandenen Mehrkanalaufnahmen nur schwer beurteilen, ob die späteren Ergebnisse des Algorithmus zuverlässig sind.

2.2 Prinzip des Beamformings und einige Algorithmen

Beamforming kann als räumliche Filtermethode verstanden werden: Entsprechend der Richtung der Schallquelle und den Unterschieden zwischen den Kanälen werden die Signale der einzelnen Mikrofone zeitlich ausgerichtet, gewichtet und kombiniert. Dadurch wird der Schall aus der Zielrichtung verstärkt, während Rauschen oder Störungen aus anderen Richtungen abgeschwächt werden. Aufnahmen eines Mikrofonarrays bilden daher die Grundlage des Beamformings. Ohne Mehrkanalaufnahme gibt es keine Zeit- und Phasenunterschiede zwischen den Kanälen, und ein Beamforming-Algorithmus kann nicht ausgeführt werden. In Sprachinteraktionssystemen wird Beamforming häufig eingesetzt, um die Qualität der Zielsprache zu verbessern, Hintergrundgeräusche zu verringern und einen saubereren Eingang für die Spracherkennung oder die Schallquellenlokalisierung bereitzustellen. Entsprechende Untersuchungen verwenden Beamforming außerdem zur Unterdrückung von Störungen, zur Lokalisierung von Schallquellen sowie als Vorverarbeitung für die Klassifikation von Audioereignissen und die Sprechererkennung (Rascon) [6]. Im Folgenden werden einige Beamforming-Algorithmen vorgestellt.

2.2.1 Delay-and-Sum-Beamforming

Das Delay-and-Sum-Beamforming, im Folgenden DAS genannt, ist der traditionellste und zugleich einer der am häufigsten verwendeten Beamforming-Algorithmen. Die Grundidee von DAS ist sehr einfach: Wenn eine von einer punktförmigen Schallquelle ausgesendete Schallwelle von einem Mikrofonarray empfangen wird, bestehen wegen der leicht unterschiedlichen Positionen der

Mikrofone relativ zur Punktschallquelle zwischen den empfangenen Signalen Zeit- und Amplitudenunterschiede. DAS nutzt genau diese Unterschiede. Zuerst wird angenommen, dass sich die Punktschallquelle an einer bestimmten Position befindet. Danach werden die empfangenen Signale entsprechend den theoretischen Verzögerungen der einzelnen Mikrofone zu dieser Position jeweils zeitlich verzögert. Dieser Vorgang wird als Ausrichtung bezeichnet. Anschließend werden alle ausgerichteten Signale addiert. Wenn die angenommene Position tatsächlich nahe an der realen Position der Schallquelle liegt, überlagern sich die Zielsignale in den Kanälen, und das Ausgangsergebnis ist stärker. Wenn diese Position nicht der realen Position der Schallquelle entspricht, lassen sich die Kanalsignale nicht gut ausrichten, und das Ergebnis nach der Addition ist schwächer. Wird dieser Vorgang für unterschiedliche mögliche Richtungen oder Positionen wiederholt, entsteht eine Karte der Schallquellenverteilung. Die Position der größten Schallintensität kann zur ungefähren Bestimmung der Position der Schallquelle verwendet werden. DAS hat die Vorteile eines klaren Prinzips, einer einfachen Umsetzung und eines geringen Rechenaufwands. Deshalb eignet es sich gut als grundlegende Beamforming-Methode oder als erster Testalgorithmus für eine Versuchsplattform. DAS hat jedoch auch deutliche Nachteile. Da es hauptsächlich auf festen Verzögerungen und einfacher Addition beruht, ist seine räumliche Auflösung begrenzt und seine Nebenkeule hoch. Dadurch können in der akustischen Karte leicht störende Ergebnisse entstehen (Licitra et al.) [7].

2.2.2 Schallquellenlokalisierung auf Grundlage von Deep Learning

Beim modernen Beamforming werden neben traditionellen Algorithmen wie DAS immer häufiger auch Kombinationen mit Machine Learning und Deep Learning untersucht. In einem System mit einem kugelförmigen Mikrofonarray werden die Ergebnisse traditioneller Verfahren durch den begrenzten Frequenzbereich beeinflusst. Bei niedrigen Frequenzen ist die Auflösung der Hauptkeule gering, während bei hohen Frequenzen leicht Nebenkeulen auftreten. Dadurch ist die Karte der Schallquellenverteilung nicht ausreichend klar. Zur Lösung dieses Problems wurde ein Deep-Learning-Modell vorgeschlagen, dessen Kernstruktur ein zweigeteilter

sphärischer Faltungsautoencoder (Dual-Branched Spherical Convolutional Autoencoder) ist. Seine Hauptaufgabe besteht darin, getrennt die unzureichende Hauptkeule bei niedrigen Frequenzen sowie die Nebenkeulen und die zu große Anzahl falscher Schallquellen bei hohen Frequenzen zu behandeln. Durch die Verarbeitung einer mit einem traditionellen Verfahren erzeugten Schallquellenkarte können Nebenkeulen und falsche Schallquellen entfernt werden. Gleichzeitig wird die Schallintensität des Hauptsignals hervorgehoben, sodass die Informationen zur Schallquellenverteilung klarer werden (Lee et al.) [8].

2.3 Akustische Bewertungskennwerte

Nach der Verarbeitung von Audio durch Beamforming lässt sich die Verbesserung der gefilterten Audioqualität häufig direkt hören. Eine Beurteilung der Verarbeitungsqualität nur mit dem menschlichen Gehör ist jedoch subjektiv und nicht quantitativ. Deshalb werden akustische Bewertungskennwerte benötigt. Sie quantifizieren bestimmte akustische Eigenschaften des Audios, damit die Aufnahmen vor und nach der Verarbeitung verglichen werden können. Im Folgenden werden einige in diesem Versuch verwendete akustische Bewertungskennwerte kurz vorgestellt.

2.3.1 Signal-Rausch-Verhältnis

Das Signal-Rausch-Verhältnis (Signal-to-Noise Ratio, SNR) bezeichnet das Verhältnis zwischen der Leistung des Hauptsignals und der Leistung des Störgeräusches im Audio. Die Formel lautet:

$$SNR = \frac{P_{signal}}{P_{noise}} \tag{2.1}$$

Dabei bezeichnet P die Leistung. Ein hohes Signal-Rausch-Verhältnis bedeutet, dass das Signal klar und leicht zu erkennen oder auszuwerten ist. Ein niedriges Signal-Rausch-Verhältnis bedeutet dagegen, dass das Signal durch Rauschen gestört oder verdeckt wird und nur schwer zu erkennen oder wiederherzustellen ist. Das Signal-Rausch-Verhältnis wird in vielen Bereichen verwendet. Neben Audiosystemen besitzt es auch in der Kommunikationstechnik, Bildverarbeitung und Radartechnik eine ähnliche Definition. Das Signal-Rausch-Verhältnis ist ein Schwerpunkt dieses Versuchs,

weil das Hauptziel des Beamformings darin besteht, die Lautstärke des Grundrauschens im verarbeiteten Audio zu verringern. Gleichzeitig werden die zu prüfenden Audiodaten aufgrund der Anforderungen des Algorithmus manchmal verstärkt. Wenn die Lautstärke der zu prüfenden Audiodaten nicht mit der Lautstärke des sauberen Referenzaudios übereinstimmt, kann sich der SNR-Wert stark verändern. Daher wird in diesem Versuch SI-SDR (Scale-Invariant Signal-to-Distortion Ratio) anstelle von SNR verwendet, da SI-SDR bei der Berechnung den Einfluss der gesamten Verstärkungsdifferenz zwischen den zu prüfenden Audiodaten und dem Referenzaudio beseitigt. Bei der Bewertung bedeutet ein höherer SI-SDR-Wert, dass die nutzbare Sprache in den zu prüfenden Audiodaten klarer ist und weniger Rauschen und Verzerrungen enthält. Ein positiver Wert bedeutet, dass die nutzbare Sprache den Hauptanteil bildet, während ein negativer Wert bedeutet, dass Rauschen und Verzerrungen den Hauptanteil bilden.

2.3.2 Short-Time Objective Intelligibility

Die Short-Time Objective Intelligibility, im Folgenden STOI genannt, ist ein objektiver Kennwert zur Vorhersage der Sprachverständlichkeit und wird häufig zur Bewertung der Sprachverbesserung eingesetzt (Kolbæk et al.) [9]. Traditionelle Bewertungskennwerte wie das SNR können nur das relative Verhältnis der Lautstärken von Signal und Rauschen beschreiben. Ob menschliche Sprache erkannt werden kann, hängt jedoch nicht immer vollständig von der Lautstärke ab. Traditionelle Verfahren sagen manchmal eine höhere Verständlichkeit nach der Rauschunterdrückung voraus, obwohl dies nicht mit den Ergebnissen realer Hörversuche übereinstimmt, weil Beamforming auch wichtige Audioinformationen entfernen kann, die für das Verständnis der Sprache erforderlich sind. STOI löst dieses Problem gut. Es vergleicht hauptsächlich das Zielaudio mit einer sauberen Sprachaufnahme, die dieselbe Sprache wie das Zielaudio enthält und als Referenzaudio dient. Für diesen Vergleich muss nicht bekannt sein, welcher Teil das Störsignal ist; stattdessen wird direkt die Ähnlichkeit zwischen Zielaudio und Referenzaudio verglichen. Der STOI-Wert liegt normalerweise zwischen 0 und 1. Ein höherer Wert bedeutet eine höhere Sprachverständlichkeit. Das

STOI-Modell ist relativ einfach und besitzt nur zwei freie Parameter. Das erhaltene Ergebnis bezieht sich direkt auf die Sprachverständlichkeit, weshalb STOI in der Forschung zu Spracherkennungsalgorithmen weit verbreitet ist. Zu beachten ist, dass die Autoren von STOI bei der Bewertung von Sprache zwei Bereiche unterscheiden: Sprachqualität und Sprachverständlichkeit. STOI konzentriert sich hauptsächlich auf die Bewertung der Sprachverständlichkeit, während die Sprachqualität, zum Beispiel ob die Stimme natürlich oder angenehm klingt, nicht berücksichtigt wird (Taal et al.) [10].

2.3.3 Perceptual Evaluation of Speech Quality

Die Perceptual Evaluation of Speech Quality, im Folgenden PESQ genannt, ist eine Reihe von Standards und enthält ein Verfahren zur automatischen Bewertung der von Nutzern eines Telefonsystems wahrgenommenen Sprachqualität. PESQ wurde im Jahr 2001 als Empfehlung ITU-T P.862 standardisiert und in den vergangenen Jahren weiterhin aktualisiert. Telefonhersteller, Anbieter von Netzwerktechnik und Telekommunikationsunternehmen verwenden PESQ für objektive Tests der Sprachqualität. Anders als die zuvor vorgestellten Bewertungskennwerte konzentriert sich PESQ nicht auf den Vergleich und die Bewertung der physikalischen Audiodaten vor und nach der Verarbeitung. PESQ geht davon aus, dass eine Bewertung der Sprachqualität allein anhand physikalischer Kennwerte wie Frequenz, Amplitude und Wellenform nicht genau ist. PESQ verwendet eine Bewertungsmethode auf Grundlage der menschlichen Hörwahrnehmung. Zuerst werden saubere Sprache und durch Rauschen gestörte Sprache mit einem Wahrnehmungsmodell jeweils als eine Reihe von Merkmalen dargestellt, die der Verarbeitung durch das menschliche Gehör entsprechen. Danach vergleicht ein kognitives Modell die Unterschiede zwischen beiden Darstellungen und sagt die subjektiv wahrgenommene Qualität der gestörten Sprache voraus. Abschließend wird das Bewertungsergebnis ausgegeben. Daher ist die mit dem PESQ-Standard bewertete Sprachqualität für Menschen anschaulicher und besser als Referenz geeignet. Der übliche Wertebereich von PESQ liegt zwischen 1,0 und 4,5. Ein höherer Wert bedeutet, dass die wahrgenommene Qualität der zu prüfenden Audiodaten

näher an der des sauberen Referenzaudios liegt.

Mit der technischen Entwicklung und der genaueren Unterteilung der Anforderungen wurden weitere Kennwerte zur Sprachbewertung vorgeschlagen. Wegen der Verbreitung und Standardisierung dieser drei Kennwerte sowie ihrer einfachen Verfügbarkeit in Python-Bibliotheken verwendet dieser Versuch hauptsächlich diese drei Kennwerte zur Bewertung nach der Beamforming-Verarbeitung.

2.4 Frühere Forschung

Frühere Untersuchungen liefern viele Ergebnisse, die für diesen Versuch als Referenz dienen können. Yang et al. erstellten den mit einem Mehrkanal-Mikrofonarray aufgenommenen Sprachdatensatz RealMAN. Ein Schwerpunkt dieses Datensatzes liegt darauf, dass das Audio in realen Umgebungen aufgenommen und nicht simuliert wurde [11]. Außerdem nutzte RealMAN eine Fischaugenkamera, um die Position des Lautsprechers aufzunehmen und daraus die Positionslabels der sprechenden Person zu gewinnen. Evers et al. zeigten in der Veröffentlichung zum Datensatz der LOCATA Challenge, dass Positionslabels zusammen mit den Richtungen der Schallquellen aufgezeichnet werden sollten. Diese räumlichen Informationen können eine Grundlage für Algorithmen zur Lokalisierung und Verfolgung von Schallquellen bilden [12]. Die MIRACLE-Datenbank von Kujawski et al. verwendet Aufnahmen in einer Laborumgebung. Ein Lautsprecher wird auf einer Gleitschiene bewegt, und seine Position wird mit einem hochgenauen zweidimensionalen Positionierungssystem bestimmt. Der maximale Fehler beträgt nur wenige Millimeter [13].

2.5 Zusammenfassung des Kapitels

Dieses Kapitel beschreibt kurz den theoretischen Hintergrund und den Forschungsstand dieses Versuchs. Es stellt Komponenten wie das im praktischen Versuch verwendete Mikrofonarray sowie unterschiedliche Arten von Beamforming-Algorithmen und ihre jeweiligen Eigenschaften vor. Abschließend erklärt es die im Versuch auf Programmebene verwendeten Werkzeuge, zum Beispiel die akustischen

Bewertungskennwerte.

3 Anforderungsanalyse und Vergleich der Lösungskonzepte

3.1 Analyse der Aufgabenanforderungen

Die Gesamtaufgabe dieses Versuchs besteht im Aufbau einer automatisierten Plattform zur Erfassung einer Sprachdatenbank. Sie soll Sprachdaten aus Situationen mit mehreren Schallquellen aus unterschiedlichen Winkeln simulieren und erfassen. Nachdem mit dieser Plattform Sprache aufgenommen und zu einer Datenbank zusammengestellt wurde, wird die Eignung der Datenbank mit Beamforming und akustischen Bewertungskennwerten bewertet. Das Endergebnis dieses Versuchs ist daher keine Analyse der Vor- und Nachteile eines bestimmten Beamforming-Algorithmus, sondern das Entwurfskonzept und der tatsächlich aufgebaute Prototyp der automatisierten Erfassungsplattform sowie die damit aufgenommene Datenbank. Um diese Versuchsziele zu erreichen, müssen die folgenden Randbedingungen und Anforderungen betrachtet werden.

3.2 Analyse der Anforderungen an das mechanische System

Um die Anforderungen an die physikalische Position und Ausrichtung der Schallquellen zu erfüllen, muss das mechanische System die folgenden Anforderungen erfüllen:

(1) Es müssen bewegliche Schallquellen oder ausreichend viele feste Schallquellen eingerichtet werden, um Quellrichtungen aus einem Bereich nahe 360° zu erreichen. Je mehr Aufnahmepositionen beziehungsweise Winkel vorhanden sind, desto realistischer simuliert das System die Eigenschaft, dass Schall in der Realität aus jeder Richtung kommen kann. Wegen der begrenzten Bewegungsgenauigkeit des mechanischen Systems ist jedoch ein bestimmter Winkelabstand zwischen den Aufnahmepositionen unvermeidbar. Mehr Aufnahmewinkel bedeuten zugleich mehr Aufnahmen und eine längere Aufnahmedauer. Daher ist eine zu große Zahl von Aufnahmewinkeln nicht realistisch. Nach einer Abwägung wurde der Winkelabstand

zwischen den Aufnahmepositionen auf 30° festgelegt. Da eine Lösung mit festen Schallquellen mehr als zehn Schallquellen erfordern würde, wirtschaftlich nicht ideal wäre und zu hohe Anforderungen an die Verkabelung und Softwaresteuerung stellen würde, wurde diese Lösung zuerst ausgeschlossen.

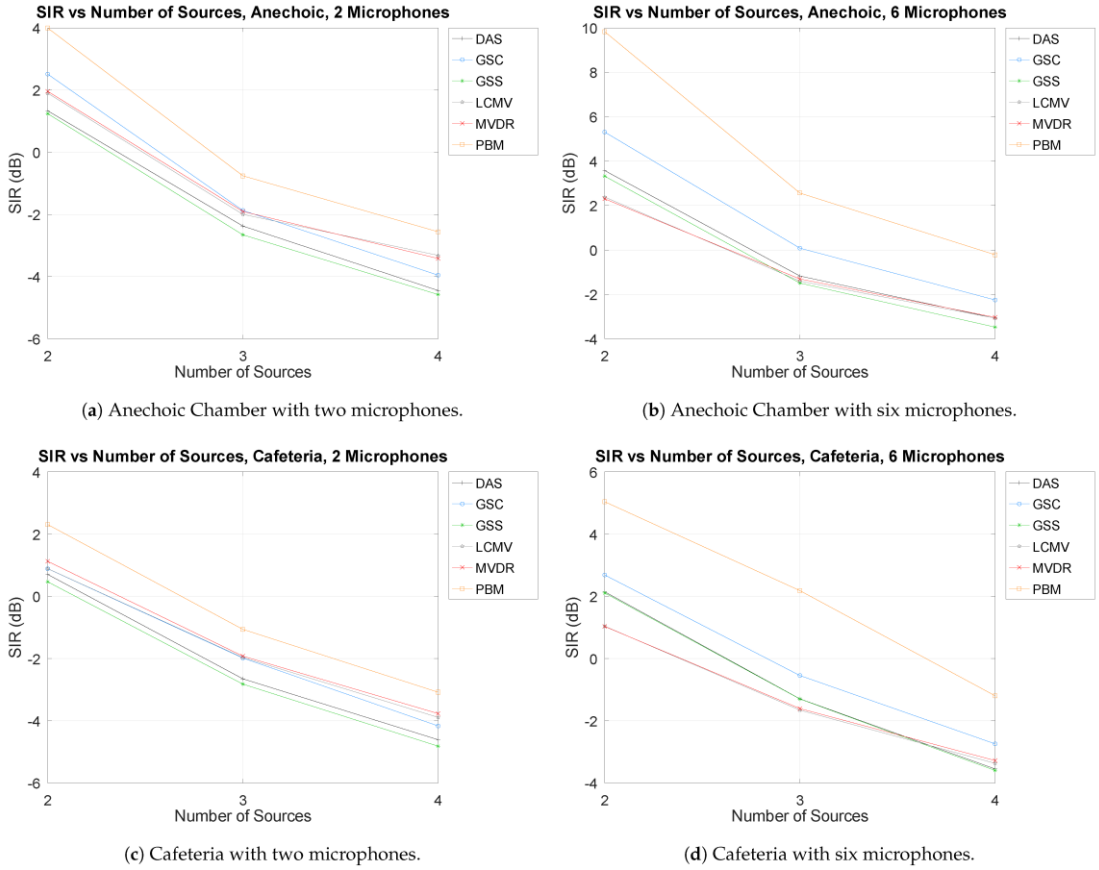
(2) Der Abstand der Schallquelle muss einer realen Anwendung entsprechen. Da diese Sprachdatenbank hauptsächlich für Mensch-Maschine-Dialoge eingesetzt werden soll und der gewöhnliche Gesprächsabstand zwischen Menschen 1 bis 3 m beträgt, muss der Abstand zwischen der Schallquelle und dem aufnehmenden Mikrofonarray in diesem Bereich liegen.

(3) Es werden mindestens zwei Schallquellen benötigt. Da in einer realen Situation neben der sprechenden Person mindestens ein Hintergrundgeräusch aus der Umgebung vorhanden ist, müssen mindestens zwei Schallquellen verwendet werden, um die Sprache und das Hintergrundgeräusch getrennt wiederzugeben. Eine größere Anzahl von Schallquellen ist jedoch nicht grundsätzlich besser. Rascon stellt fest, dass bei einer Aufnahme mit sechs Mikrofonen das Signal-Interferenz-Verhältnis nach der Beamforming-Verarbeitung bei drei Schallquellen im Vergleich zu zwei Schallquellen deutlich sinkt, die Verarbeitungswirkung also deutlich schlechter wird. Bei vier Schallquellen ist die Situation noch schlechter (siehe Abbildung 1). Daher hilft die Verwendung nur einer Hauptsprachquelle und einer Hintergrundgeräuschquelle dabei, eine zu schlechte spätere Beamforming-Wirkung zu vermeiden.

(4) Der relative Winkel zwischen dem Mikrofonarray und dem Raum muss verändert werden können. Der Raumnachhall ist ein wichtiger Faktor für die Wirkung des Beamformings. Da die meisten Räume rechteckig sind und die Abstände der einzelnen Wände zu den Mikrofonen nicht gleich sind, verändern sich die Nachhallbedingungen bei der Drehung des Mikrofonarrays. Wenn nur eine einzige Nachhallbedingung betrachtet wird, lassen sich die meisten realen Situationen nicht gut simulieren.

Für jede der genannten Bewegungen muss die Wiederholbarkeit gewährleistet werden. Wenn sich das System erneut an dieselbe von der Software festgelegte

Position bewegt, dürfen lockere mechanische Bauteile, Bewegungsträgheit und andere Ursachen keine zu große Positionsabweichung erzeugen. Dadurch sollen die Aufnahmeergebnisse unter denselben Bedingungen übereinstimmen. Dies stellt hohe Anforderungen an die Gesamtstabilität des mechanischen Systems.



(a) Anechoic Chamber with two microphones.

(b) Anechoic Chamber with six microphones.

(c) Cafeteria with two microphones.

(d) Cafeteria with six microphones.

Abbildung 1: Signal-Interferenz-Verhältnis (SIR) bei unterschiedlicher Anzahl von Schallquellen [6]

3.3 Analyse der Anforderungen an das Steuerungssystem

Für diesen Versuch werden zwei Hauptsteuerungssysteme benötigt. Das erste System steuert die Bewegung der Schallquellen. Vor dem Beginn jeder Aufnahme sollen die Schallquellen damit an die vorgegebene Position bewegt werden. Dabei ist zu beachten, dass die meisten auf dem Markt verfügbaren Schallquellen Lautsprecher sind und ihre Schallöffnung gewöhnlich nur in eine Richtung zeigt. Damit sich der Schall hauptsächlich geradlinig und ohne Hindernis von der Quelle zum Mikrofon ausbreitet, anstatt zunächst an einer Wand reflektiert zu werden, soll die Schallöffnung des Lautsprechers immer zum Mikrofonarray zeigen. Eine Drehbewegung der

Schallquelle um das Mikrofonarray als Mittelpunkt ist deshalb eine natürliche und einfache Bewegungsform. Das zweite System steuert den Winkel zwischen dem Mikrofonarray und den Wänden. Dieses System verlangt, dass sich das Mikrofon um eine horizontale und eine vertikale Achse drehen, vor der Aufnahme den vorgegebenen Winkel erreichen und diesen Winkel während der Aufnahme halten kann. Da sowohl das Mikrofonarray als auch die Wände symmetrisch geformt sind, muss sich das Mikrofonarray in horizontaler Richtung nicht um 360° drehen. Bei rechteckigen Wänden und einem rechteckigen Mikrofonarray reicht ein horizontaler Drehbereich von 90° aus, um alle Situationen zu simulieren, wenn sich das Mikrofonarray in der Raummitte befindet.

3.4 Analyse der Anforderungen an die Sprachdatenbank

Das Endziel der akustischen Datenerfassung ist der Aufbau einer geeigneten Sprachdatenbank. Diese Datenbank muss die folgenden Eigenschaften besitzen:

(1) Sie enthält Aufnahmen mit unterschiedlichen Positionen, unterschiedlicher menschlicher Sprache und unterschiedlichen Störgeräuschen, unterschiedlichen Sprachlängen sowie unterschiedlichen Nachhallbedingungen. Die menschliche Sprache umfasst dabei unterschiedliche Gesprächsinhalte und unterschiedliche sprechende Personen und kann bei Bedarf auch unterschiedliche Lautstärken enthalten. Zu den Störgeräuschen gehören Umgebungsgeräusche und störende menschliche Sprache.

(2) Die zu jeder Aufnahme gehörenden Informationen werden gekennzeichnet. Dazu gehören die Position der Schallquelle, die Dateinamen der verwendeten Sprach- und Geräuschquellen, die Lautstärke der einzelnen Schallquellen sowie der Drehwinkel und der horizontale Neigungswinkel des Mikrofonarrays. Ohne diese Informationen kann das Beamforming nicht ordnungsgemäß durchgeführt werden.

3.5 Vergleich der Konzepte und endgültig ausgewähltes Konzept

Die größte Schwierigkeit beim Aufbau der gesamten Versuchsplattform liegt im Entwurf der Bewegung der Schallquellen. Nach einer ersten Auswahl werden in dieser

Arbeit zwei mögliche Konzepte vorgeschlagen. Das erste ist ein Schwenkarmkonzept: Das Mikrofonarray befindet sich in der Mitte. Mehrere Motoren werden mit senkrecht zum Boden stehenden Wellen neben dem Mikrofonarray auf derselben festen Grundplatte montiert und bilden die Systemmitte. Ein Ende eines langen horizontalen Schwenkarms wird über eine Kupplung mit der Motorwelle verbunden. Das andere Ende des horizontalen Schwenkarms wird mit einem Plattformwagen auf Rädern verbunden, der einen Lautsprecher trägt. Die Motorwelle dreht dadurch den horizontalen Schwenkarm um den Motor. Der horizontale Schwenkarm bewegt den Wagen wiederum um die gesamte Systemmitte. Dadurch verändert sich die Position der Schallquelle relativ zum Mikrofonarray. Das zweite Konzept ist ein Schienenkonzept. Dabei wird um das Mikrofonarray als Mittelpunkt eine kreisförmige Schiene verlegt. Ein Wagen mit einem Lautsprecher bewegt sich entlang dieser Schiene, um das Ziel zu erreichen. Beide Konzepte besitzen Vor- und Nachteile. Die für das Schwenkarmkonzept erforderlichen Bauteile sind auf dem Markt relativ leicht erhältlich. Es gibt keine komplexe oder unbekannte Montage, das Montagekonzept ist klar, und die gesamte Plattform benötigt nur wenig Fläche. Sie kann deshalb beim Wechsel des Versuchsraums jederzeit zerlegt und bewegt werden. Das Konzept stellt jedoch hohe Anforderungen an das Motordrehmoment, besitzt eine geringere Stabilität und benötigt mehr Bauteile. Das Schienenkonzept ist einfach zu verstehen und benötigt insgesamt weniger zu beschaffende Bauteile. Eine kreisförmige Schiene mit einem Radius von mindestens 1 m ist auf dem Markt jedoch sehr selten, und eine Sonderanfertigung ist teuer. Außerdem ist das Bewegungskonzept des Wagens auf der Schiene nicht klar oder durch den Schienenhersteller beschränkt, wodurch sich die Abmessungen des Wagens später nicht einfach anpassen lassen. Die mit einer gewichteten Bewertungsmethode erstellte Tabelle ist in Tabelle 1 dargestellt.

	Schwenkarmkonzept			Schienenkonzept		
	Bewertung	Gewichtung	Gewichtete Punktzahl	Bewertung	Gewichtung	Gewichtete Punktzahl
Grad der Funktionserfüllung	4	0.4	1.6	4	0.4	1.6
Systemstabilität	3	0.25	0.75	4	0.25	1
Montageschwierigkeit	4	0.15	0.6	2	0.15	0.3
Beschaffungspreis und -schwierigkeit	3	0.2	0.6	0	0.2	0
Gesamtpunktzahl			3.55			2.9

Tabelle 1: Gewichtete Bewertung des Schwenkarm- und des Schienenkonzepts (4 steht für ausgezeichnet, 3 für gut, 2 für mittel und 0 für sehr schlecht oder nicht umsetzbar)

Tabelle 1 zeigt, dass die Beschaffungskosten und die Beschaffungsschwierigkeit des Schienenkonzepts so ungünstig sind, dass das Konzept nicht umgesetzt werden kann. Deshalb wurde das Schwenkarmkonzept endgültig ausgewählt.

3.6 Zusammenfassung des Kapitels

Dieses Kapitel analysiert ausführlich die physikalischen Anforderungen, die Anforderungen an das Steuerungsprogramm und die Anforderungen an die Datenbank, die von der Versuchsplattform zur Erreichung des Versuchsziels erfüllt werden müssen. Abschließend werden zwei erste Entwurfskonzepte vorgeschlagen, und die endgültige Entwurfsrichtung wird mit einer gewichteten Bewertungsmethode bestimmt.

4 Entwurf und Aufbau des mechanischen Systems

4.1 Gesamtentwurf

Der endgültige Entwurf der Erfassungsplattform für die Sprachdatenbank ist in Abbildung 2 dargestellt. Der mittlere Bereich enthält das Mikrofonarray und seine Antriebsmotoren, die Schrittmotoren für die Drehung der Schwenkarme und die entsprechenden Verbindungsteile sowie einen Raspberry Pi. Der Raspberry Pi sendet Bewegungssignale an die einzelnen Motoren, steuert den Beginn und das Ende der Aufnahme mit dem Mikrofonarray und speichert die Aufnahmen vorübergehend. Diese Bauteile werden auf einer ebenen Holzgrundplatte befestigt. Durch die Reibung zwischen der Holzplatte und dem Boden bleibt das System während des gesamten Betriebs stehen. An beiden Seiten befinden sich zwei Wagen mit Lautsprechern. Die Wagen sind über die Schwenkarme mit den Motoren verbunden und bewegen die Lautsprecher. Einige nicht befestigte Teile, zum Beispiel Kabel und Stromversorgungen, sind in der Entwurfszeichnung nicht dargestellt.

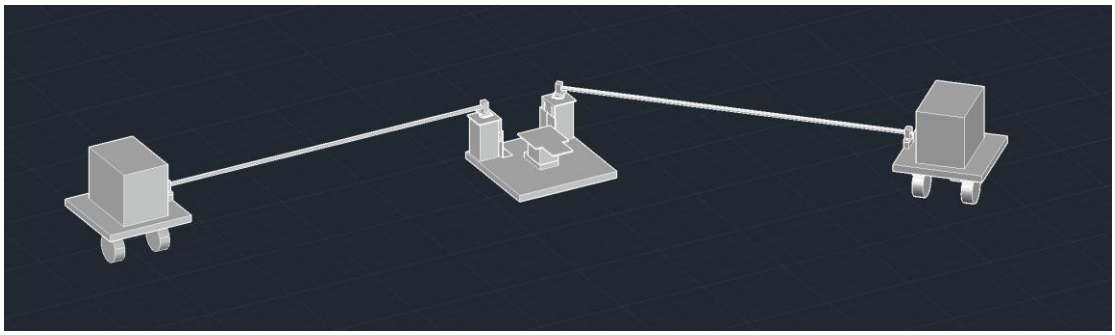


Abbildung 2: Gesamtentwurf der Erfassungsplattform für die Sprachdatenbank (vereinfachte Darstellung)

4.2 Entwurf der Verbindungsteile für den Schwenkarmantrieb

Abbildung 3a und Abbildung 3b zeigen den genauen Verbindungsaufbau des Schwenkarmantriebs. Das linke Bauteil in Abbildung 3b ist ein dreieckiger Verstärkungswinkel. Rechts befinden sich von oben nach unten ein Wellenhalter, eine Klemmnabe, eine Schrittmotorhalterung und ein Schrittmotor.

Der Motor ist das zentrale Bauteil des Antriebs. Bei der Auswahl des Motors müssen das Haltemoment und die Motorabmessungen berücksichtigt werden. Das Haltemoment des Motors wird mit der folgenden Formel berechnet:

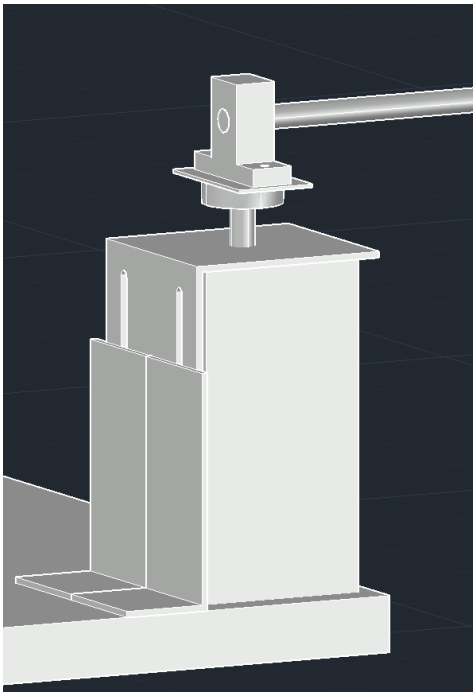
$$M = \mu G l + J\alpha \tag{4.1}$$

In Gleichung 4.1 ist M das Haltemoment, μ der Rollwiderstandskoeffizient zwischen Rad und Boden, G die Summe der auf Wagen und Lautsprecher wirkenden Gewichtskräfte und l der Abstand zwischen der Motorwelle und dem geometrischen Mittelpunkt des Wagens. Da die Breite des Wagens deutlich kleiner als die Länge des Schwenkarms ist, entspricht l hier ungefähr der Länge des Schwenkarms. J ist das Massenträgheitsmoment des Lautsprecherwagensystems, und α ist die maximale Winkelbeschleunigung bei seiner Bewegung. Da diese Plattform keine bestimmte Bewegungsgeschwindigkeit des Wagensystems verlangt, kann der Wagen durch die Softwaresteuerung langsam bewegt und die Winkelbeschleunigung dadurch stark verringert werden. Der Term der Winkelbeschleunigung wird deshalb vernachlässigt. Das endgültige Haltemoment hängt hauptsächlich vom Produkt aus μ, G und l ab. Der Rollwiderstandskoeffizient ist umgekehrt proportional zur Härte des Radmaterials und zum Raddurchmesser sowie direkt proportional zur Rauheit des Bodens, zur Umgebungstemperatur und zur relativen Bewegungsgeschwindigkeit (Jansson) [14]. Daher ist es nahezu unmöglich, einen genauen Rollwiderstandskoeffizienten nur durch eine theoretische Berechnung zu bestimmen. In der Industrie wird für Kunststoffräder auf Fliesenböden im Allgemeinen ein Rollwiderstandskoeffizient von 0,03 bis 0,05 verwendet. Nach einer einfachen Schätzung beträgt die Gesamtgewichtskraft des Lautsprecherwagensystems etwa 20 N bis 30 N. Der genaue Wert ändert sich leicht mit der Auswahl der Räder und dem Lautsprechermodell. Für die Länge des Schwenkarms wird ein auf dem Markt üblicher Wert für glatte lange Stangen verwendet. Glatte Stangen mit einer für den Versuch geeigneten Länge von 1 bis 3 m sind auf dem Markt meistens mit Längen von 1 m und 2 m erhältlich. Deshalb wird zunächst eine Länge von 2 m angenommen. Daraus ergibt sich für das Haltemoment des Motors ein geschätzter Bereich von 1,2 Nm bis 3 Nm. Daher wird

ein Motor mit einem Haltemoment von 3 Nm ausgewählt.

Nach der Festlegung des Motordrehmoments werden die Motorabmessungen bestimmt. Länge, Breite und Höhe des Motorgehäuses sind dabei nicht der wichtigste Punkt. Entscheidend ist der Durchmesser der Motorwelle. Die Welle muss groß genug sein, um das bei der Bewegung entstehende Drehmoment ohne Torsion aufzunehmen. Gleichzeitig muss die Verbindung mit der Klemmnabe berücksichtigt werden. Ein Wellendurchmesser, der zu den üblichen Bohrungsdurchmessern handelsüblicher Klemmnaben passt, soll bevorzugt werden. Schrittmotoren mit einem Drehmoment von 3 Nm sind mit unterschiedlichen Wellendurchmessern von 6,35 mm, 7,5 mm, 8 mm und 10 mm erhältlich. Nach einer gemeinsamen Abwägung wurde ein Schrittmotor mit einem Wellendurchmesser von 8 mm ausgewählt. Viele handelsübliche Klemmnaben werden außerdem mit einer Madenschraube befestigt. Dabei drückt eine Schraube von einer Seite gegen die Motorwelle. Deshalb soll eine D-förmige Motorwelle ausgewählt werden.

Nach der Festlegung des Motors werden die Ausführungen der Klemmnabe und des Wellenhalters bestimmt. Klemmnaben richten sich häufig nach denselben Fertigungsstandards. Daher sind Abstand und geometrische Anordnung der oberen Bohrungen bei handelsüblichen Klemmnaben mit gleichem Bohrungsdurchmesser weitgehend einheitlich. Dies gilt ebenso für die unteren Bohrungen der Wellenhalter. Der Abstand der unteren Bohrungen des Wellenhalters passt jedoch nicht zum Abstand der Bohrungen der Klemmnabe. Deshalb soll die Klemmnabe in diesem Versuch bearbeitet werden, um einen passenden Bohrungsabstand zu erhalten (siehe Abbildung 4).



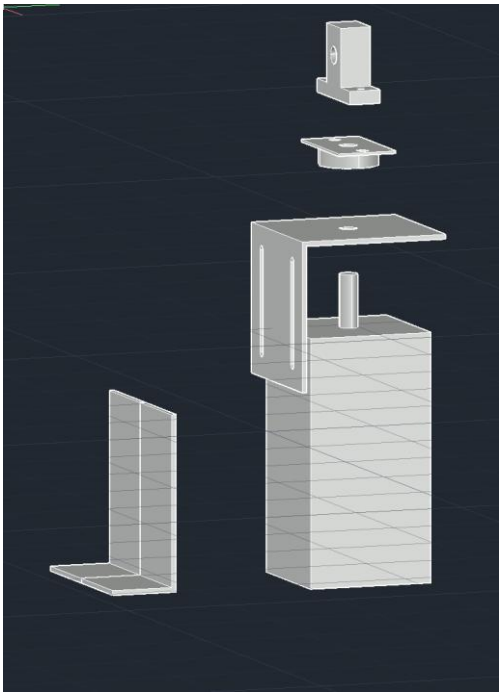


Abbildung 3a: Vergrößerte Darstellung des Schwenkarmantriebs

Abbildung 3b: Genauer Verbindungsaufbau des Antriebs

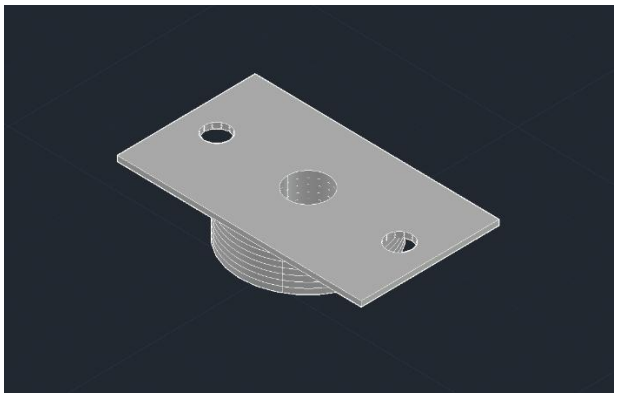


Abbildung 4: Entwurf der Bohrungspositionen an der Klemmnabe

4.3 Entwurf der Schwenkarmstruktur

Beim Entwurf des Schwenkarms müssen zuerst seine Länge und sein Gewicht berücksichtigt werden. Die Länge des Schwenkarms beeinflusst direkt das Drehmoment, das bei der Bewegung des Wagens um die zentrale Grundplatte entsteht, und bestimmt damit das erforderliche Haltemoment des Motors. Zu beachten ist jedoch, dass auch das Gewicht des Schwenkarms das Gesamtgewicht und das Massenträgheitsmoment des rotierenden Systems beeinflusst. Das Gewicht ist proportional zum Rollwiderstand. Bei einem zu großen Massenträgheitsmoment lässt

sich der Einfluss des Produkts aus Massenträgheitsmoment und Winkelbeschleunigung auf das Drehmoment auch bei kleiner Winkelbeschleunigung nicht mehr einfach vernachlässigen. Nach der Auswahl wurde schließlich beschlossen, eine 2 m lange glatte Aluminiumrundstange zu beschaffen. Der Hauptgrund für die Verwendung einer glatten Stange besteht darin, dass sie von einer Halterung leicht festgeklemmt werden kann und bei der Bewegung keine Relativbewegung entsteht.

4.4 Entwurf des Lautsprecherwagens

Die Hauptschwierigkeit beim Entwurf des Wagens liegt in der Auswahl der Räder, da die Räder den Spitzenwert des Widerstandsmoments bestimmen und damit den größten Einfluss auf das erforderliche Motordrehmoment haben. Zuerst müssen die Bewegungsbahn und die Belastungsart der Räder geklärt werden. Der Wagen soll sich zunächst auf einer Kreisbahn mit einem Radius von 2 m bewegen. Deshalb wirken auf die Räder nicht nur tangentiale Rollwiderstände; bei festen Rädern tritt zusätzlich eine Reibung in Normalrichtung auf. Wenn nur die Verringerung dieser Reibung betrachtet wird, erscheinen Lenkrollen als die bessere Wahl. Wenn jedoch alle Räder als Lenkrollen ausgeführt werden, ist zu beachten, dass der Boden in der Realität nicht vollständig eben ist. Wegen kleiner Unebenheiten können die Ausrichtungen mehrerer Lenkrollen von der Tangente der Kreisbahn abweichen. Wenn mehrere Lenkrollen gleichzeitig falsch ausgerichtet sind, wirken wegen der unterschiedlichen Bewegungsrichtungen der Räder plötzlich sehr große Widerstände auf den Wagen. Dies muss im realen Betrieb vermieden werden. Daher ist eine Lösung mit einer führenden Lenkrolle und festen übrigen Rädern besser als eine Lösung ausschließlich mit Lenkrollen. Eine Lenkrolle bringt jedoch ein weiteres Problem mit sich. Der Wagen bewegt sich hin und her, sodass seine Bewegung zwangsläufig von der Drehrichtung im Uhrzeigersinn in die Drehrichtung gegen den Uhrzeigersinn wechselt, oder umgekehrt. Beim Richtungswechsel muss sich die Lenkrolle um 180° drehen. Da Radachse und Lenkachse nicht auf derselben Achse liegen, muss das Rad um die Lenkachse über den Boden gleiten. Dabei müssen neben

der statischen Rollreibung zusätzlich die durch das Gleiten des Rades auf dem Boden entstehenden Reibungskräfte überwunden werden (Arrizabalaga et al.) [15]. Der Spitzenwert dieser Reibungskraft kann größer sein als der Widerstandsspitzenwert einer Lösung ausschließlich mit festen Rädern. Deshalb müssen die Spitzenwerte der Widerstände in zwei Fällen verglichen werden: erstens die Reibung beim Drehen einer Lenkrolle und zweitens die Summe aus Haftreibung und Reibung in Normalrichtung beim Anfahren ausschließlich fester Räder aus dem Stillstand. Da der Gleitreibungskoeffizient ungefähr 0,3 beträgt und damit um eine Größenordnung größer als der Rollreibungskoeffizient ist, wird hauptsächlich die Gleitreibung der Lenkrolle und der festen Räder auf dem Boden verglichen. Das Reibungsmoment beim Drehen der Lenkrolle wird mit der folgenden Formel berechnet:

$$M_{swivel} = \mu N e \tag{4.2}$$

In Gleichung 4.2 ist e der Abstand zwischen der Radachse und der Lenkachse.

Es wird angenommen, dass die durch das Gleiten der Lenkrolle auf die drehende Plattform wirkende Kraft F_{swivel} ist. Dann gilt:

$$F_{swivel} = \frac{M_{swivel}}{R} = \mu N \frac{e}{R} \tag{4.3}$$

In Gleichung 4.3 ist R der Drehradius der Plattform.

Die Kraft, die durch das Gleiten eines festen Rades auf die drehende Plattform wirkt, lautet:

$$f = \mu N sin\alpha \tag{4.4}$$

In Gleichung 4.4 ist α der Winkel zwischen der Bewegungsrichtung und der tatsächlichen Rollrichtung des festen Rades.

Zusammenfassend müssen die Größen von F_{swivel} und f und damit die Größen von e/R und sin α verglichen werden. Nach einer Schätzung gilt e/R = 0,04 und sin α = 0,025. Deshalb wurde eine Lösung ausschließlich mit festen Rädern gewählt. Da eine kleinere Anzahl von Rädern das Gesamtgewicht des Systems möglichst stark verringert, wird eine Lösung mit einem Rad vorne und zwei Rädern hinten verwendet.

Als Nächstes werden Material und Abmessungen der Räder betrachtet. Übliche Werkstoffe für kleine Räder sind Stahl, Gusseisen, Kunststoff und Gummi. Nach

Versuchen hängt der Rollwiderstand eines Rades von der aufgenommenen Last N, dem Radradius R und dem Elastizitätsmodul E des Radwerkstoffs ab. Je größer N und je kleiner R und E sind, desto größer ist der Rollwiderstand (Kumar et al.) [16]. Deshalb sollen möglichst leichte Werkstoffe mit großem Raddurchmesser und kleiner Verformung unter Belastung ausgewählt werden. Gleichzeitig müssen die Verfügbarkeit auf dem Markt und der Preis berücksichtigt werden. Nach einem Vergleich wurden schließlich Polypropylenräder (PP) mit einem Durchmesser von 80 mm ausgewählt.

Abschließend werden die übrigen Probleme behandelt. Ein mögliches Hauptproblem besteht darin, dass der Schwenkarm den Wagen mit dem Antriebsmotor verbinden muss. Deshalb müssen die an diesen beiden Bauteilen montierten Wellenhalter auf derselben Höhe liegen. Andernfalls erzeugt die Neigung des Schwenkarms einen zusätzlichen Widerstand in vertikaler Richtung und beeinflusst die Wagenbewegung. Nach einer ersten Berechnung liegt der Wellenhalter am Wagen etwas niedriger als der Wellenhalter am Motor. Als erste Lösung wird eine zusätzliche Holzplatte auf die Grundplatte des Wagens, also die den Lautsprecher tragende Holzplatte, gelegt, um ihre Höhe zu vergrößern. Wenn der Wellenhalter auf dieser erhöhten Grundplatte montiert wird, kann der Schwenkarm waagerecht bleiben.

4.5 Entwurf der Steuerstruktur des Mikrofonarrays

Um die Drehung des Mikrofonarrays um eine horizontale und eine vertikale Achse zu ermöglichen, wird in diesem Versuch ein Raspberry-Pi-Schwenk-Neige-Kit mit zwei Freiheitsgraden verwendet (Abbildung 5). Ein solches Kit wird häufig eingesetzt, wenn eine Kamera mit einem Raspberry Pi bewegt werden soll. Nach der Montage kann der Raspberry Pi über GPIO-Kanäle Signale ausgeben und die beiden Motoren in der Schwenk-Neige-Einheit steuern, die jeweils für die horizontale und vertikale Drehung zuständig sind. Zu beachten ist, dass die kleinen Servomotoren in der Schwenk-Neige-Struktur im Unterschied zu Schrittmotoren nach dem Einschalten ihre Position nicht automatisch halten können. Wenn das montierte Mikrofonarray zu schwer ist, kann es sich daher durch die Schwerkraft mit der Schwenk-Neige-Struktur

nach unten drehen. Da außerdem die Befestigungsart des Mikrofonarrays nicht zum Entwurf der Schwenk-Neige-Struktur passt, muss ein zusätzliches Verbindungsteil zwischen Mikrofonarray und Schwenk-Neige-Struktur entworfen werden.

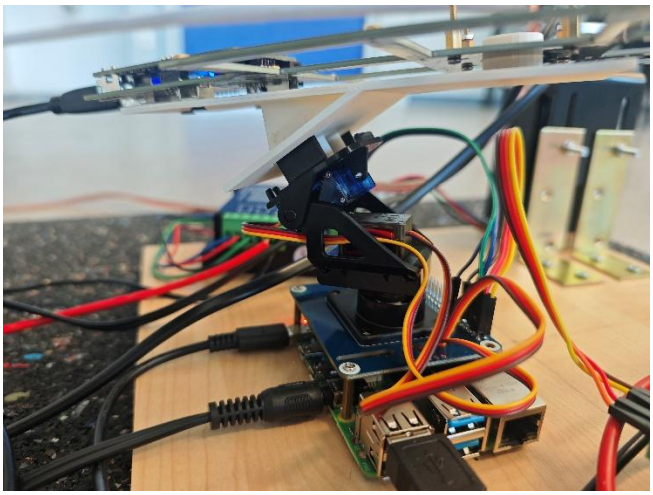


Abbildung 5: Darstellung der Schwenk-Neige-Struktur und ihrer Einbauposition

4.6 Entwurf der Befestigungsstruktur des Mikrofonarrays

Das Befestigungsteil des Mikrofonarrays ist in Abbildung 6 dargestellt. Sein Entwurf wurde in drei Versionen weiterentwickelt. Beim Entwurf müssen zwei Punkte besonders berücksichtigt werden: erstens die Lagebeziehung zwischen Mikrofonarray und Drehachse und zweitens die Verteilung des Schwerpunkts der gesamten Struktur. Da die Versuchsplattform wiederholte Winkeleinstellungen durchführen muss, erhöht ein zu großer Abstand zwischen dem Schwerpunkt des Mikrofonarrays und der Drehachse die Motorbelastung und verringert zugleich die Stabilität während der Bewegung. Deshalb wurde die Verbindungsstruktur im Entwurfsprozess mehrfach verbessert. Beim Entwurf der ersten Version ganz links lag das Hauptziel darin, die mechanische Verbindung und Befestigung zwischen Mikrofonarray und Schwenk-Neige-Struktur umzusetzen. Deshalb wurde zuerst die Montierbarkeit der Struktur sichergestellt. Im praktischen Entwurf wurde jedoch nicht ausreichend berücksichtigt, dass der geometrische Mittelpunkt des Mikrofonarrays möglichst nahe an der Drehachse liegen soll. Wenn zwischen dem Drehzentrum und dem Mittelpunkt des Mikrofonarrays eine große Abweichung besteht, entsteht beim Drehen des Mikrofonarrays nicht nur ein zusätzliches Drehmoment. Auch der

Drehbereich kann begrenzt und die Motorbelastung erhöht werden. Die erste Version erfüllt deshalb zwar die Grundfunktion, aber nicht die Anforderungen an eine stabile Bewegung. Zur Lösung der Probleme der ersten Version wurde eine zweite Struktur entworfen. In dieser Version wurde der Verbindungsbereich so verändert, dass die Position des Mikrofonarrays näher am Drehzentrum der Schwenk-Neige-Struktur liegt. Dadurch kann das bei der Drehung entstehende exzentrische Moment verringert und die theoretische Bewegungsstabilität erhöht werden. Bei der praktischen Montage und Erprobung zeigte sich jedoch, dass auch die zweite Version noch Probleme besitzt. Obwohl der Abstand zwischen Drehachse und Mittelpunkt des Mikrofonarrays verringert wurde, wird die Bewegung des Mikrofonarrays durch einen Motor auf derselben Grundplatte behindert. Dadurch ist der Bewegungsbereich begrenzt. Auf Grundlage der Testergebnisse wurde deshalb eine dritte Struktur entworfen, die sich in der Abbildung ganz rechts befindet. In dieser Version wurden Form und Einbauposition des Verbindungsteils neu entworfen, sodass der geometrische Mittelpunkt und der Schwerpunkt des Mikrofonarrays noch näher am Drehzentrum der Schwenk-Neige-Struktur liegen. Dadurch wird nicht nur das vom Motor bereitzustellende Antriebsmoment verringert, sondern auch ein Zusammenstoß zwischen Mikrofonarray und Motor vermieden. Das System kann die Winkeleinstellung somit stabiler durchführen.

Im Folgenden wird der Fertigungsablauf dieses Bauteils kurz beschrieben. Zuerst wird die entsprechende Zeichnung in AutoCAD erstellt. Danach wird die fertige Zeichnung in UltiMaker Cura importiert, um den 3D-Druck vorzubereiten (Abbildung 7). Zuerst muss die Ausrichtung des zu druckenden Teils bestimmt werden. Mit der richtigen Ausrichtung kann die beim Drucken erforderliche Menge an zusätzlichem Stützmaterial verringert werden. Dadurch wird sowohl die Druckzeit verkürzt als auch das spätere Entfernen des zusätzlichen Stützmaterials erleichtert. Ein Vergleich zeigt, dass das Bauteil am besten in der dargestellten Lage gedruckt wird. Danach wird die Fülldichte auf 20 % eingestellt, als Füllmuster wird ein Dreiecksmuster und als Stützstruktur eine Baumstruktur ausgewählt. Dadurch besitzt das Bauteil eine

ausreichende Festigkeit, ohne zu schwer zu werden. Nach einer Vorschau des Druckvorgangs kann die Fertigung durch 3D-Druck begonnen werden.

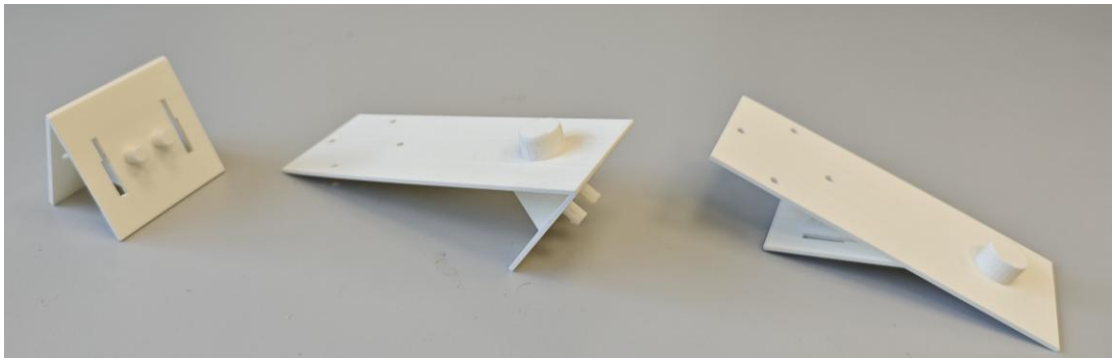


Abbildung 6: Befestigungsteile des Mikrofonarrays; von links nach rechts die erste, zweite und dritte Entwurfsversion

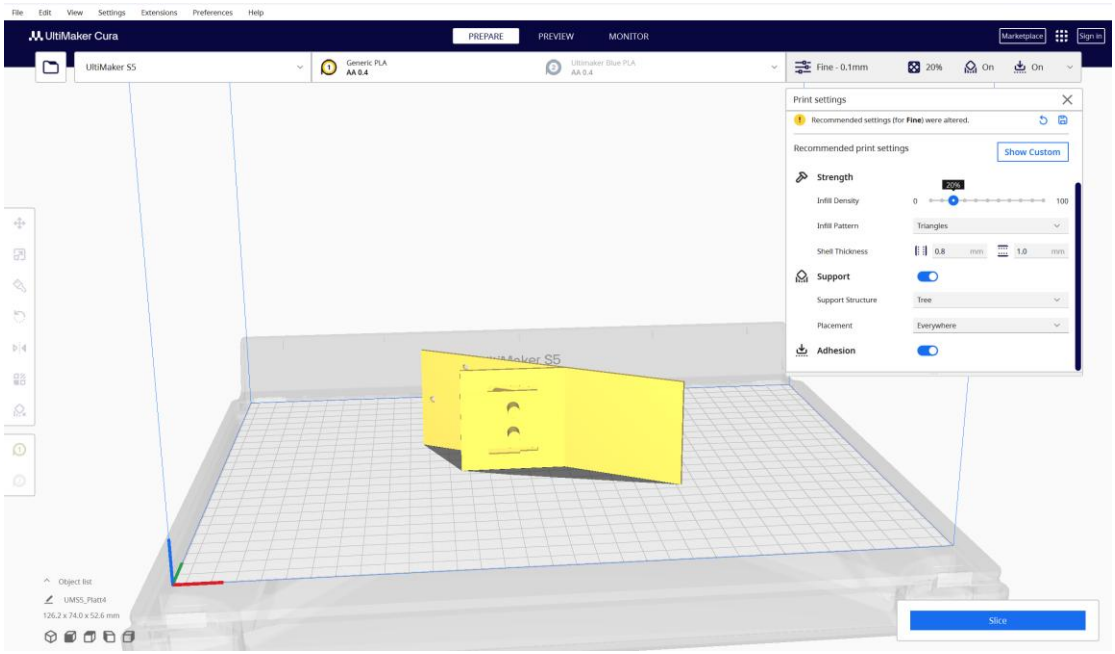


Abbildung 7: Oberfläche zur Vorbereitung des 3D-Drucks

4.7 Praktische Montage und Anpassung

Die endgültigen Maßskizzen sind in den Abbildungen 8a und 8b dargestellt. Einige wiederholte Bauteile und Teile mit festen Abmessungen sind in den Abbildungen nicht beschriftet.

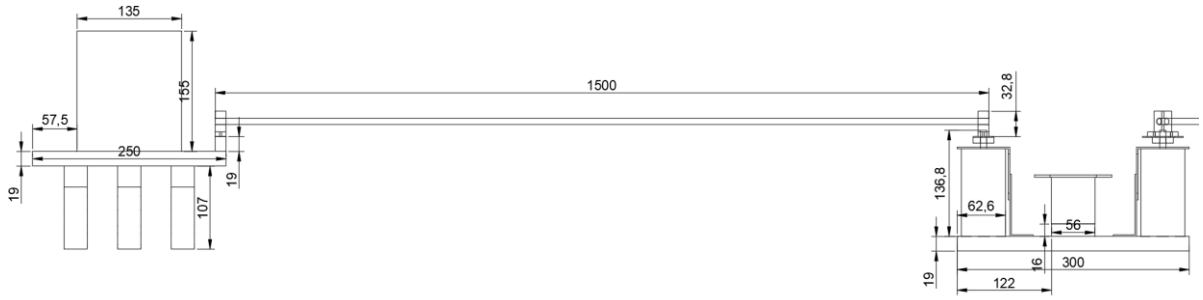


Abbildung 8a: Vorderansicht mit Abmessungen (teilweise)



Abbildung 8b: Draufsicht mit Abmessungen (teilweise)

Bei der praktischen Montage sind wegen Montagefehlern oder Abweichungen zwischen der realen Situation und der theoretischen Schätzung Anpassungen oder sogar ein neuer Entwurf unvermeidbar. Im Folgenden werden einige im praktischen Aufbau aufgetretene Schwierigkeiten und ihre Lösungen beschrieben.

Bei der praktischen Montage wurde festgestellt, dass sich der Schwenkarm beim Bewegen des Wagens unter dem Biegemoment selbst durchbiegt. Seine Durchbiegung lautet:

$$\delta = \frac{FL^3}{3EI} \tag{4.5}$$

In Gleichung 4.5 ist F die Kraft am Stangenende, L die Stangenlänge, E der Elastizitätsmodul und I das Flächenträgheitsmoment. In der realen Situation verändert die Durchbiegung des Schwenkarms die Richtung der Kraft an seinem Ende. Dadurch wirkt das Antriebsmoment nicht vollständig in Tangentialrichtung der Kreisbahn. Das wirksame Moment wird kleiner, und das vom Motor bereitzustellende Moment steigt. Es gibt zwei Verbesserungsmöglichkeiten. Die erste besteht in einer Verkürzung der Stange. Dadurch werden sowohl die Durchbiegung als auch das Drehmoment

verringert. Die zweite besteht in einer Vergrößerung des Flächenträgheitsmoments I, denn:

$$I = \frac{\pi D^4}{64} \tag{4.6}$$

Eine dickere Stange kann die Durchbiegung deshalb wirksam verringern. Eine dickere Stange erhöht jedoch auch das Gewicht, und passende Teile wie Wellenhalter müssen neu beschafft werden. Nach einer Abwägung wurde die Stangenlänge schließlich von 2 m auf 1,5 m verringert und der Stangendurchmesser von 8 mm auf 10 mm vergrößert. Dadurch wird die Durchbiegung der Stange wirksam verringert und gleichzeitig der Motor entlastet.

Bei einem Langzeittest der Schrittmotoren wurde festgestellt, dass bei einem über längere Zeit eingeschalteten, aber stillstehenden Motor die Strombelastung des Motors allmählich steigt und sich seine Temperatur erhöht. Nach drei Stunden erreicht das Motorgehäuse eine Temperatur von bis zu 110 °C. Da eine Aufnahme mit der Versuchsplattform häufig länger als drei Stunden dauern soll, stellt die hohe Gehäusetemperatur ein Sicherheitsrisiko dar. Zur Lösung dieses Problems wurde am Treiber eine Halbierung des Ruhestroms eingestellt. Wenn der Motor nicht arbeitet, wird der fließende Strom dadurch automatisch verringert und die Erwärmung stark reduziert. Ein Nachteil besteht darin, dass das Haltemoment im Stillstand kleiner wird. Da im Stillstand keine zusätzliche Kraft auf die Versuchsplattform wirkt, ist die Halbierung des Ruhestroms eine einfache und geeignete Lösung.

Zur Befestigung des Schrittmotors an der zentralen Grundplatte sah der erste Entwurf vor, eine Schrittmotorhalterung am Motor zu montieren und die Motorhalterung auf einer Seite des Motors mit zwei dreieckigen Verstärkungswinkeln an der Grundplatte zu befestigen. Dadurch sollte eine Eigendrehung des Motors während des Betriebs verhindert werden. Im Betrieb mit realer Last zeigte sich jedoch, dass die beiden Winkel wegen des großen aufgenommenen Drehmoments durch die Elastizität des Metalls leicht verdreht werden, wenn der Motor ein Drehmoment liefert. Der Motor verdreht sich deshalb weiterhin leicht um etwa 3° bis 5°. Um den Motor vollständig zu befestigen, wurden in diesem Versuch zwei

Begrenzungsschrauben an den Nuten des Motorgehäuses angebracht. Diese beiden Schrauben nehmen nicht die hauptsächliche vom Motor erzeugte Scherkraft auf, sondern unterstützen nur die dreieckigen Verstärkungswinkel. Mit dieser Methode kann eine sichtbare Drehung des Motors vollständig verhindert werden.

Das endgültig montierte reale System ist in Abbildung 9 dargestellt.

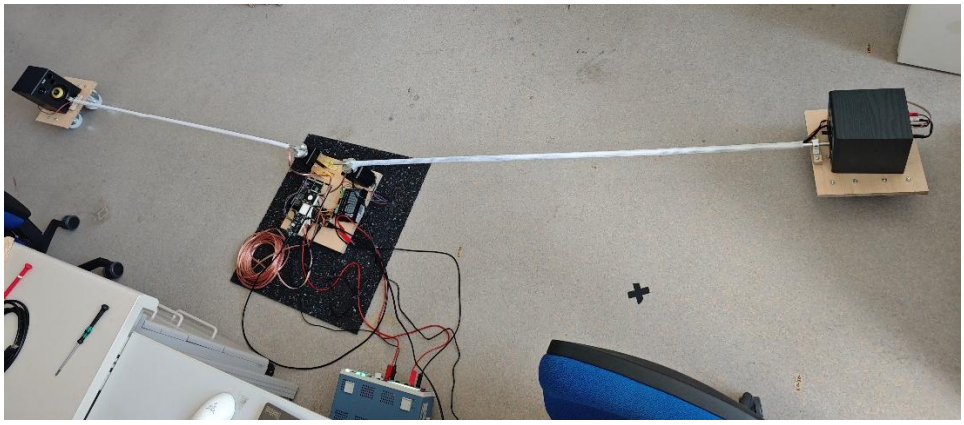


Abbildung 9: Fertig montiertes reales System

4.8 Zusammenfassung des Kapitels

Dieses Kapitel beschreibt den genauen Entwurf der Versuchsplattform sowie den Ablauf von der Auswahl und Beschaffung der Bauteile bis zum Aufbau des realen mechanischen Systems. Außerdem stellt es das Entwurfskonzept und den Fertigungsprozess der Befestigungsstruktur des Mikrofonarrays vor und beschreibt die bei der Montage aufgetretenen praktischen Probleme und ihre Lösungen.

5 Entwurf des Elektronik- und Steuerungssystems

5.1 Gesamtsteuerung und Ablauf

Die Steuerung der Versuchsplattform besteht aus der Bewegungssteuerung der Wagen, der Bewegungssteuerung des Mikrofonarrays sowie der Steuerung der Audiowiedergabe und -aufnahme. Da der Schrittmotor die Bewegung des Wagens direkt steuert und der Drehwinkel der Motorwelle direkt mit der Position des Wagens zusammenhängt, kann der Drehwinkel der Motorwelle als Ausgang der Steuerung verwendet werden. Entsprechend können beim Mikrofonarray die Drehwinkel der beiden Motoren in der Schwenk-Neige-Einheit als Ausgänge verwendet werden. Die Eingangssignale dieser beiden Steuerungsabläufe werden über GPIO-Anschlüsse von einem Raspberry Pi ausgegeben, der direkt unter der Schwenk-Neige-Einheit des Mikrofonarrays montiert ist. Die Steuerung der Audiowiedergabe und -aufnahme ist relativ einfach. Über die am Raspberry Pi vorhandenen 3,5-mm- und USB-Anschlüsse können die Wiedergabe der Lautsprecher gestartet und beendet, die wiederzugebenden Audiodateien ausgewählt und die Aufnahme des Mikrofonarrays gesteuert werden. Der Raspberry Pi selbst wird über einen Laborcomputer ferngesteuert. Mit Fernkommunikationstechniken wie VNC und SSH sind eine grafische Interaktion und eine Dateiübertragung zwischen Computer und Raspberry Pi möglich.

Der gesamte Arbeitsablauf des Systems ist in Abbildung 10 dargestellt.

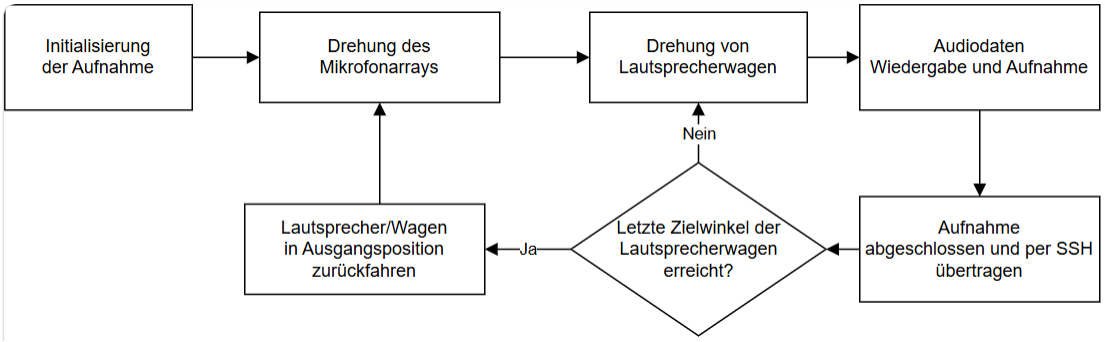


Abbildung 10: Arbeitsablauf der Versuchsplattform

5.2 Stromversorgung

Da der Laborcomputer, der Raspberry Pi und die Lautsprecher gewöhnliche Netzspannung verwenden und die Schwenk-Neige-Einheit direkt über den Raspberry Pi versorgt wird, betrifft die Auswahl der Stromversorgung hauptsächlich die Schrittmotoren. Der Treiber der Schrittmotoren ist ein ACT DM856 mit einer Eingangsspannung von 24 bis 80 V. Er kann deshalb nicht direkt über einen gewöhnlichen Haushaltsanschluss mit einem Ladegerät versorgt werden. Der maximale Nennstrom des Motors beträgt außerdem 4,2 A. Wenn die Leistung der Stromversorgung nicht ausreicht, kann der Motor seine maximale Leistung möglicherweise nicht erreichen, wodurch das Drehmoment zu klein wird. Zur Lösung dieses Problems wird in diesem Versuch ein Labornetzgerät mit zwei Kanälen verwendet. Jeder Kanal liefert maximal 32 V, und das Netzgerät liefert maximal 5 A. Es stellt für beide Treiber ausreichend Leistung bereit. Ein Nachteil besteht darin, dass das Labornetzgerät schwer ist und viel Platz benötigt. Es muss deshalb darauf geachtet werden, dass es nicht mit anderen Bauteilen in Konflikt kommt.

Die endgültige Kabelanordnung der Versuchsplattform ist in Abbildung 11 dargestellt.

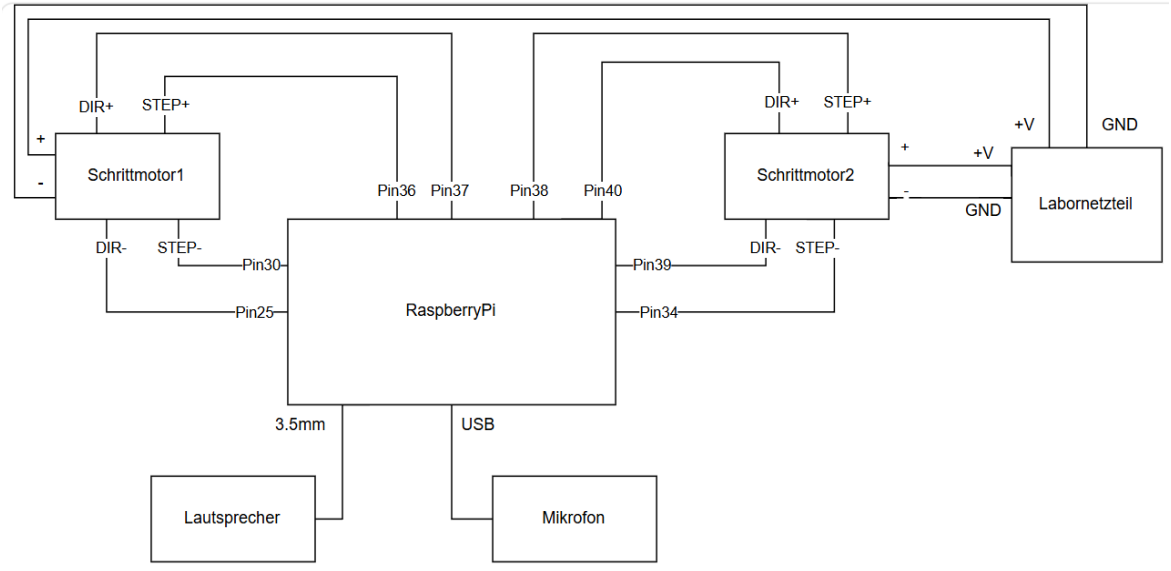


Abbildung 11: Kabelanordnung

5.3 Kabelanforderungen und Kabelführung

Für den Versuch werden folgende Kabel benötigt: ein Lautsprecherkabel zwischen dem aktiven und dem passiven Lautsprecher, ein AUX-Kabel zwischen dem aktiven Lautsprecher und dem 3,5-mm-Anschluss sowie Stromkabel zur Versorgung elektronischer Komponenten wie Lautsprecher, Raspberry Pi und Motoren. Die Kabel, die mit der zentralen Grundplatte verbunden werden müssen, also die Stromkabel des Raspberry Pi und der Motortreiber, werden direkt in derselben Richtung herausgeführt. In den späteren Versuchen sollen die Wagen nicht in diese Richtung fahren, damit sie nicht mit der Verkabelung zusammenstoßen. Kabel, die mit den Lautsprechern verbunden werden müssen, zum Beispiel AUX-Kabel, Lautsprecherkabel und Stromkabel der Lautsprecher, dürfen während der Bewegung nicht in die Wagenräder geraten, da dies die normale Bewegung der Wagen beeinträchtigen würde. Deshalb werden im Versuch mehrere Kabel zusammen mit dem Schwenkarm in einem geflochtenen Kabelschlauch geführt. Dadurch bewegen sich die Kabel mit dem Schwenkarm, anstatt in der Luft zu hängen oder auf dem Boden zu liegen, und beeinflussen den Wagen nicht.

5.4 Steuerung des Mikrofonarrays

Das Mikrofonarray führt zwei Bewegungen aus: Schwenken und Neigen. Diese beiden Bewegungen werden jeweils von einem MG90S-Servomotor, im Folgenden Schwenkservo genannt, und einem SG90-Servomotor, im Folgenden Neigeservo genannt, gesteuert. Der gesamte Steuerungsablauf kann einfach so beschrieben werden: Der Raspberry Pi sendet ein Signal für die Bewegung zur Zielposition. Nachdem der Schwenk- und der Neigeservo das Signal empfangen haben, drehen sich ihre Motorwellen auf den zu dieser Position gehörenden Winkel. Im Folgenden wird die genaue Umsetzung der Steuerung beschrieben.

Zuerst muss die Systemumgebung eingerichtet werden. Der Raspberry Pi dient als zentrale Steuereinheit des gesamten Systems, kann die Servomotoren jedoch nicht direkt steuern. Für die Kommunikation mit den Motoren werden deshalb zusätzliche Dateien und offizielle Bibliotheken benötigt. Eine wichtige Rolle spielen dabei das offizielle Softwarepaket des Schwenk-Neige-Systems und die Python-Bibliothek

smbus. Mit diesen Bibliotheken kann der Raspberry Pi über die I2C-Schnittstelle dynamische Befehle an die Motoren senden. Dabei muss sichergestellt werden, dass der I2C-Kerneltreiber des Raspberry Pi vorher aktiviert wurde. Nach der Einrichtung der entsprechenden Umgebung wurde vor dem Versuch ein kurzer Kommunikationstest zwischen Raspberry Pi und Servomotoren durchgeführt, damit die späteren Programme normal ausgeführt werden können. Für den Test werden nach dem Aufruf der entsprechenden Bibliotheken und dem Start der Servomotoren Befehle an den Schwenk- und den Neigeservo gesendet, sich auf einen bestimmten Winkel zu bewegen. Wenn sie sich bewegen können, funktioniert die Kommunikation normal.

Zu beachten ist, dass diese Servomotormodelle nur eine interne Rückmeldung der Winkelposition besitzen und der Raspberry Pi den tatsächlichen internen Winkel des Servomotors nicht von außen abfragen kann. Wenn die Servowelle vor dem Start des Servomotors durch menschlichen Einfluss oder das Gewicht des Mikrofonarrays verdreht wird, hat sich der interne Winkel des Servomotors beim Start bereits verändert, während das Raspberry-Pi-System weiterhin annimmt, dass sich die Servowelle an der Position vor dem letzten Ausschalten befindet. Wenn das Programm nun eine Bewegung von 1° ausgehend vom ursprünglichen Winkel vorgibt, ist der reale Winkel bereits verändert. Die Servowelle dreht sich dann häufig deutlich weiter als 1° und bewegt sich mit sehr hoher Geschwindigkeit auf diesen Zielwinkel. Wegen der hohen Geschwindigkeit und der nicht steuerbaren Bewegung kann sich das Mikrofonarray dabei leicht lösen oder sogar beschädigt werden. Um dieses Problem zu vermeiden, wird im Programm eine Ruheposition festgelegt. Nach jeder Aufnahme soll sich das Mikrofonarray vor dem Ausschalten auf eine bestimmte Position bewegen. In dieser Position kann sich die Welle unter dem Einfluss der Schwerkraft nur schwer selbstständig neigen. Solange sie nicht von einer Person berührt wird, bewegt sich der Servomotor beim nächsten Einschalten deshalb nicht plötzlich.

Nach dem Start in der Ruheposition muss das Steuerungssystem das Mikrofonarray auf einen bestimmten Winkel drehen und dort auf den

Aufnahmebeginn warten. Nach dem Ende der Aufnahme dreht es sich auf die nächste Position. Die Steuerungslogik legt die einzelnen Wellenpositionen entsprechend den vorgegebenen Abständen fest. Wenn die Welle eine bestimmte Position erreicht, wird die Drehrichtung umgekehrt. Diese Hin- und Herbewegung wird fortgesetzt, bis ein Ausschaltbefehl empfangen wird. Danach bewegt sich die Welle zur Ruheposition und das System wird ausgeschaltet. Auch bei dieser Drehbewegung besteht das Problem einer zu hohen Geschwindigkeit. Die endgültige Lösung besteht darin, den Servomotor ähnlich wie einen Schrittmotor zu bewegen. Bei jedem Schritt wird nur ein sehr kleiner Winkel, zum Beispiel 1°, gedreht. Danach wird eine kurze Pause, zum Beispiel 0,05 s, eingefügt. Mit dieser Methode wird die Bewegungsträgheit kleiner und die Systemstabilität höher. Durch die genannten Methoden wurden eine vollständig automatische Steuerung während der Aufnahme und der Beginn der nächsten Aufnahme ohne zusätzliche Konfiguration umgesetzt.

5.5 Steuerung der Lautsprecherwagen

Das Steuerungsprinzip des Wagens ähnelt dem des Mikrofonarrays: Die Motorwelle dient als Ausgang, und der Raspberry Pi sendet das Steuersignal. Ein Unterschied besteht darin, dass der Schrittmotor elektrische Impulssignale empfängt. Der Raspberry Pi muss deshalb nur elektrische Signale über GPIO übertragen, um mit dem Schrittmotor zu kommunizieren; eine zusätzliche Konfiguration ist nicht erforderlich. Der Schrittmotor besitzt außerdem keine interne Positionsrückmeldung. Er erhält also keinen Befehl, sich auf eine bestimmte Position zu drehen, sondern bewegt sich entsprechend der Anzahl der Impulse nur um eine bestimmte Schrittzahl. Das beim Servomotor vorhandene Rücksetzproblem beim Start besteht beim Schrittmotor deshalb nicht.

Ähnlich wie beim Mikrofonarraysystem besteht die Steuerungslogik des Lautsprecherwagensystems darin, dass sich die Wagen jeweils in Abständen von 30° bewegen und die Drehrichtung des Motors beim Erreichen der festgelegten Grenze umgekehrt wird. Die Bewegungsgrenze der Lautsprecherwagen wird durch die Symmetrieachse der zentralen Grundplatte bestimmt. Damit die beiden Wagen nicht

zusammenstoßen, darf keiner der Wagen die Symmetrieachse der Grundplatte überschreiten. Da die Antriebsmotoren nicht auf der Symmetrieachse montiert sind, besitzt jeder Wagen theoretisch einen Bewegungsbereich von etwas mehr als 180°. In der Realität werden jedoch einige Stromversorgungskabel von der Mitte der Grundplatte entlang einer Richtung der Symmetrieachse herausgeführt. Damit sich die Wagen nicht in diesen Kabeln verfangen, wird der reale Bewegungsbereich auf 120° begrenzt. So bleibt ausreichend Platz für die Kabelführung, und ein Zusammenstoß wird vermieden, wenn sich beide Wagen am Rand der Symmetrieachse befinden. Auch die Bewegungsgeschwindigkeit der Wagen wird über die Drehzahl der Welle gesteuert. Eine Änderung der Impulsfrequenz beeinflusst unmittelbar, wie schnell sich die Wagen bewegen. Dies ist für den realen Aufnahmeablauf sehr wichtig. Bei einer zu langsamen Bewegung benötigt der Wagen mehr Zeit, um jede Position zu erreichen. Die gesamte Aufnahmedauer wird dadurch weiter verlängert, die Effizienz sinkt und der Energieverbrauch steigt. Bei einer zu schnellen Bewegung werden die Beschleunigung beim Anfahren und Bremsen sowie das Massenträgheitsmoment größer, wodurch sich das Motordrehmoment erhöht.

5.6 Aufnahmekonfiguration und -steuerung

Die Versuchsplattform verwendet ein UMA-16-Mikrofonarray zur Audioaufnahme (siehe Abbildung 12). Im Unterschied zu einem gewöhnlichen Mikrofon kann dieses Mikrofonarray gleichzeitig 16 unabhängige Roh-Audiokanäle ausgeben. Diese Kanäle gehören jeweils zu unterschiedlichen Mikrofonen des Arrays. Durch die Speicherung der Audiodaten und Positionsinformationen der unterschiedlichen Kanäle können spätere Algorithmen die Schallinformationen aus unterschiedlichen räumlichen Positionen verarbeiten und das Beamforming wirksamer durchführen. Vor der Mehrkanalaufnahme mit diesem Mikrofonarray muss zuerst die Systemumgebung eingerichtet werden. Da das Array 16 Audiokanäle ausgibt, kann gewöhnliche Zweikanal-Aufnahmesoftware nicht richtig auf alle Kanäle zugreifen und keine 16-kanalige Ausgabeaufnahme erzeugen. Im auf dem Raspberry Pi installierten Linux-System kann die im System vorhandene Mehrkanal-

Aufnahmeschnittstelle ALSA (Advanced Linux Sound Architecture) verwendet werden. Durch den Aufruf von ALSA mit Python, die Einstellung der richtigen Gerätenummer und Kanalzahl sowie die Auswahl einer geeigneten Abtastrate ist die Aufnahmekonfiguration des Mikrofonarrays abgeschlossen.

Die Steuerungslogik des Aufnahmeablaufs ist eng mit der Steuerung der beiden Bewegungssysteme verbunden. Erst wenn sowohl die Wagen als auch das Mikrofonarray die vorgegebenen Positionen erreicht haben, dürfen Lautsprecher und Mikrofon ihre Arbeit beginnen. Zu diesem Zeitpunkt gibt ein Lautsprecher menschliche Sprache und der andere ein störendes Hintergrundgeräusch wieder, während das Mikrofonarray mit der Aufnahme beginnt. Nach dem Ende der Sprachwiedergabe soll die Aufnahme zusammen mit passenden Metadaten gespeichert werden.

Zusammenfassend setzt dieser Versuch die vollständige Steuerungslogik für die Positions- und Winkeländerung der Lautsprecher und des Mikrofonarrays sowie für die gemeinsame Wiedergabe und Aufnahme um. Nachdem die einzelnen Logikabläufe jeweils als aufrufbare Funktion verpackt wurden, kann die Erfassungsplattform einfach Einstellungen wie den Beginn der Aufnahme, das wiederzugebende Audiomaterial, die Winkelabstände der Wagen- und Mikrofonarraybewegungen sowie die Anzahl der Hin- und Herbewegungen selbst festlegen und damit die automatische Steuerung der Erfassungsplattform umsetzen.

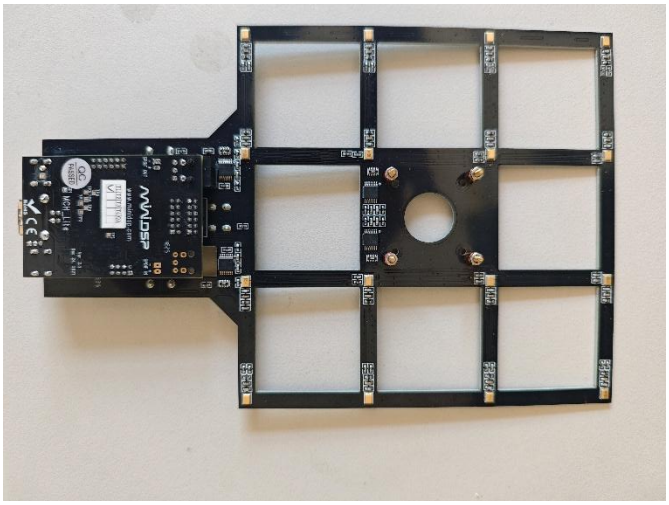


Abbildung 12: Der UMA-16-Mikrofonarray

5.7 Zusammenfassung des Kapitels

Dieses Kapitel beschreibt den Entwurf der Gesamtsteuerungslogik der Erfassungsplattform sowie die Anordnung und Positionierung der elektronischen Bauteile. Es erklärt außerdem die genauen Bewegungskonzepte und die jeweilige Steuerungslogik der Lautsprecherwagen und des Mikrofonarrays sowie die Hauptlogik der Audioaufnahme.

6 Vorbereitung und Ablauf der Datenerfassung

6.1 Herkunft und Auswahl des Audiomaterials

Das Audiomaterial besteht hauptsächlich aus zwei Teilen: sauberer menschlicher Sprache und Hintergrundgeräusch. Der Sprachteil soll keine zusätzlichen Störgeräusche enthalten und klar ausgesprochen sein, damit das endgültige Training des Deep-Learning-Modells nicht durch eine geringe Qualität des Ausgangsmaterials beeinflusst wird. Bei der Suche nach Sprachmaterial können außerdem die folgenden Eigenschaften bevorzugt werden:

(1) Die gesamte Audiomenge der Materialdatenbank ist groß und deckt einen breiten Bereich ab. Sie enthält also Aufnahmen von unterschiedlichen sprechenden Personen mit unterschiedlichen Inhalten. Dadurch kann einerseits sichergestellt werden, dass die endgültige Sprachdatenbank ausreichend viele Audiodaten für das Lernen des Modells enthält. Andererseits kann die Generalisierungsfähigkeit des Modells durch die Kombination unterschiedlicher sprechender Personen und unterschiedlicher Texte erhöht werden.

(2) Die Dauer jedes Materialabschnitts darf nicht zu lang sein. Für Deep Learning ist die Lerneffizienz am höchsten, wenn jede Aufnahme ein bis zwei Sätze enthält und insgesamt 3 bis 20 s dauert. Zu lange Sprachaufnahmen müssten dagegen manuell nach Sätzen in kleinere Abschnitte geschnitten werden und würden zusätzlichen Arbeitsaufwand erzeugen.

(3) Ein vorhandener Transkriptionstext. Der zum Audio gehörende Text ist für einige Bewertungen notwendig. Bei einer großen Menge an Sprachmaterial würde es zusätzliche Zeit kosten, jede Audiodatei mit Spracherkennung oder sogar durch menschliches Hören in Text umzuwandeln. Auch die Richtigkeit könnte nicht gewährleistet werden. Wenn jede Audiodatei bereits den entsprechenden Text enthält, kann dieses Problem vermieden werden.

Nach einer gemeinsamen Prüfung verwendet dieser Versuch schließlich einen

Teil von LibriSpeech als Datenbank für das saubere Sprachmaterial. LibriSpeech ist ein Korpus mit etwa 1000 Stunden englischer, mit 16 kHz abgetasteter vorgelesener Sprache. Sein Ziel ist die Unterstützung des Trainings und Tests automatischer Spracherkennungssysteme (Panayotov et al.) [17]. Unterschiedliche sprechende Personen und unterschiedliche Texte sind nummeriert. Der größte Teil des Materials wurde Satz für Satz aus längeren Abschnitten herausgeschnitten und enthält den zu jedem Abschnitt gehörenden Text. Insgesamt erfüllt LibriSpeech die meisten Anforderungen an die Auswahl des Audiomaterials.

Die Hauptanforderungen an das Hintergrundgeräusch lauten: Das Geräusch soll dauerhaft und stabil sein und nicht zeitweise vollständig fehlen oder zeitweise eine zu hohe Lautstärke besitzen. Dadurch wird vermieden, dass in einzelnen Aufnahmen zufällig keine Geräuschstörung vorhanden ist und das Label dadurch ungenau wird. Gleichzeitig soll Hintergrundgeräusch bevorzugt werden, das besser zur vorgesehenen Versuchssituation passt. Bei Aufgaben zur Spracherkennung von Robotern sind Besprechungsräume, Flure und Eingangshallen häufige Situationen, und die Geräusche bestehen hauptsächlich aus Sprache. Das Geräuschmaterial dieses Versuchs stammt aus der DEMAND-Datenbank. Im Unterschied zu anderen häufig verwendeten Geräuschdatenbanken, die reale Geräusche eher im Labor simulieren, enthält sie mehr Mehrkanal-Umgebungsgeräusche aus unterschiedlichen Innen- und Außenumgebungen (Thiemann et al.) [18].

6.2 Entwurf der Sprachdatenbank

Die Sprachdatenbank dient schließlich dem Modelltraining oder der Bewertung vorhandener Algorithmen. Da sie viele Audiodateien mit einer komplexen Einteilung enthält, müssen vor den realen Aufnahmen zum Aufbau der Datenbank ihre Gesamtstruktur und die enthaltenen Dateien entworfen werden.

6.2.1 Entwurf der Gesamtstruktur

Die Ebenenstruktur der Sprachdatenbank wird anhand von drei Labels gegliedert: Geräuschbedingung, Lautsprecherwinkel und Mikrofonwinkel. Die wichtigste

Eigenschaft dieser Sprachdatenbank besteht darin, Sprache mit unterschiedlichen Positionen der Schallquellen und unterschiedlichen Winkeln des Mikrofonarrays zu enthalten. Die Kombinationen aus Positionen und Winkeln sind sehr vielfältig. Damit Sprachaufnahmen mit demselben Positionslabel schnell gefunden und gemeinsam für das Training verwendet werden können, ordnet der Versuch die Ebenen von Kombinationen mit wenigen Änderungen zu Kombinationen mit vielen Änderungen. Die Geräuschbedingung bildet den Ordner der ersten Ebene, der Winkel des Mikrofonarrays den Ordner der zweiten Ebene und die Winkel der beiden Lautsprecher den Ordner der dritten Ebene. Im Ordner der dritten Ebene werden alle an dieser Position aufgenommenen Sprachdateien und die zugehörigen Sprachmetadaten gespeichert.

6.2.2 Entwurf der enthaltenen Dateien

Die wirksamen Dateien in der Sprachdatenbank sind Sprachaufnahmen und Sprachmetadaten. Zuerst müssen die gesamte Anzahl und die gesamte Aufnahmedauer der Sprachdateien betrachtet werden. Wenn sich die Lautsprecher jeweils in Abständen von 30° und das Mikrofonarray in Abständen von 45° bewegen, besitzt jeder Lautsprecher fünf Messpositionen und das Mikrofon drei Messpositionen. Die Kombination aller Positionen ergibt insgesamt 75 Positionen. Wenn an jeder Position zu viele Aufnahmen erstellt werden, steigt nicht nur die Aufnahmedauer um ein Vielfaches, sondern auch der Speicherbedarf. Dies wäre für diesen Versuch schwer tragbar. Bei der ersten Datenerfassung werden deshalb an jeder Position 16 Audiodateien aufgenommen. Sie bestehen aus jeweils zwei Sätzen von acht unterschiedlichen sprechenden Personen. Die Geräusche werden nur in zwei Gruppen eingeteilt: mit Geräusch, wobei das Geräusch immer aus Stimmen in einem Besprechungsraum besteht, und ohne Geräusch. Damit liegt die gesamte Aufnahmedauer an jeder Position unter 4 min, die wirksame Aufnahmedauer beträgt etwa 3 min und die gesamte Datenmenge der Aufnahmen an jeder Position beträgt 477 MB. Diese Werte liegen in einem akzeptablen Bereich.

Auch Sprachmetadaten sind ein notwendiger Bestandteil der Datenbank. In

diesem Versuch enthalten die Metadatendateien folgende Informationen: Sprecher-ID, Satz-ID, Satztext, Geräuschname, Winkel der Lautsprecher und des Mikrofonarrays sowie Lautstärke der Sprache und des Geräusches. Bei der realen Aufnahme wird die Metadatendatei nach dem Ende jeder Aufnahme automatisch erzeugt.

6.3 Verbesserungen nach Aufnahmetests und endgültiger Steuerungscode

Bei den Aufnahmetests traten einige praktische technische Probleme auf. Für diese Probleme wurde die Steuerungslogik gezielt verbessert.

6.3.1 Speicherung der Aufnahmen

Da die Audiomenge groß ist, 16-kanaliges Audio selbst viele Daten enthält und die vom Raspberry Pi verwendete MicroSD-Speicherkarte nur eine begrenzte Kapazität besitzt, müssen die Audiodateien nach der Aufnahme eines Teils der Daten rechtzeitig von der Speicherkarte des Raspberry Pi übertragen werden. Die einfachste Methode besteht darin, einen USB-Stick mit großer Kapazität am Raspberry Pi anzuschließen, die Aufnahmedateien direkt auf dem USB-Stick zu speichern und sie anschließend vom USB-Stick auf den Bürocomputer oder den Server zu übertragen. Diese Lösung ist einfach und wirksam und benötigt nur wenige Änderungen am Programmcode. Die Gesamtkapazität des USB-Sticks ist jedoch weiterhin begrenzt. Außerdem können die Aufnahmen nicht in Echtzeit empfangen und geprüft werden. Deshalb verwendet dieser Versuch eine andere Lösung: Auf dem Computer wird ein Zielordner erstellt. Der Raspberry Pi überträgt die Aufnahmedateien in bestimmten Abständen über SSH in diesen Ordner. Nach der Übertragung werden die Audiodateien auf dem Raspberry Pi gelöscht, um neuen Speicherplatz zu schaffen. Dabei entsteht das neue Problem, dass der Raspberry Pi vor jeder Übertragung das Passwort des Computers eingeben soll. Untersuchungen zeigten, dass eine Anmeldung ohne Passwort möglich ist, wenn der Computer dem Schlüssel des Raspberry Pi vertraut. Dadurch ist bei der Dateiübertragung über SSH keine Passworteingabe mehr erforderlich und das Problem wird gelöst. Der Vorteil dieser Methode besteht im Empfang der Audiodateien in Echtzeit. Der Nachteil ist die

begrenzte SSH-Übertragungsgeschwindigkeit, durch die sich die gesamte Aufnahmedauer verlängert.

6.3.2 Vorbereitung vor der ersten Aufnahme

Bei den praktischen Tests endete die erste Aufnahme jedes Erfassungsvorgangs bereits nach nur 1 s. Nach einer Prüfung wurde als Ursache ein instabiler Aufnahmestrom beim ersten Start des Mikrofonarrays bestimmt. Deshalb wurde am Anfang jedes Erfassungsvorgangs eine Gerätevorbereitung ergänzt: Das Mikrofonarray nimmt zuerst 2 s lang auf, und diese Aufnahme wird verworfen. Dadurch soll verhindert werden, dass das Problem beim Start der eigentlichen Aufnahme auftritt. Da das System nach dem früheren Fehler der ersten Aufnahme die folgenden Aufnahmen trotzdem fortsetzte, konnte der Fehler ohne spätere Kontrolle nur schwer entdeckt werden. Deshalb wurde dem Programm zusätzlich eine Prüfung jeder einzelnen Aufnahme hinzugefügt. Die nächste Aufnahme kann erst beginnen, wenn die Länge der Aufnahme mit der Länge des Ausgangsmaterials übereinstimmt.

6.3.3 Wiedergabepufferzeit

Während der Aufnahme tritt gelegentlich ein Fehler des Aufnahmepuffers (Overrun) auf. Dadurch geht ein Teil der Daten bei der Abtastung verloren. Das Programm enthält deshalb einen Aufnahmepuffer von 1 s, damit die Daten bei einer kurzen hohen Systemauslastung rechtzeitig geschrieben werden können. Audiodateien, bei denen bereits ein Pufferfehler aufgetreten ist, werden vom System automatisch erneut aufgenommen. Erst wenn fünf Aufnahmen hintereinander die Anforderungen nicht erfüllen, wird der gesamte Aufnahmeablauf beendet. Dadurch werden schwerwiegende Fehler in den endgültigen Aufnahmen vermieden und zugleich die Fehlertoleranz des Systems erhöht.

Nach Abschluss aller Aufnahmeaufgaben erzeugt das System schließlich automatisch ein Fehlerprotokoll. Es zeigt, welche Dateien während der Datenerfassung wegen eines Pufferfehlers oder eines ähnlichen Problems erneut aufgenommen wurden, und erleichtert dadurch eine spätere Verbesserung des Ablaufs.

6.4 Erste Bewertung der Aufnahmeergebnisse

In diesem Versuch wurden schließlich insgesamt 1200 Sprachaufnahmen mit Störgeräusch erfasst. Sie umfassen die Kombinationen aus jeweils fünf unterschiedlichen Positionen der beiden Lautsprecher und drei Winkeln des Mikrofonarrays, insgesamt also 75 unterschiedliche Positionssituationen. Jede Situation enthält insgesamt 16 unterschiedliche Sätze von acht sprechenden Personen. Zusätzlich wurden 240 Referenz-Sprachaufnahmen ohne Störgeräusch erstellt. Diese umfassen fünf Positionen eines Lautsprechers und drei Winkel des Mikrofonarrays, insgesamt also 15 Kombinationen. Es wurden weiterhin dieselben 16 Sätze aufgenommen.

Nach der Datenerfassung wurden zufällig ausgewählte Aufnahmen angehört. Der Gesamteindruck war klar und gut. Es müssen jedoch weiterhin zwei Probleme beachtet werden. Erstens ist die gesamte Signalstärke gering. Wegen der begrenzten Lautsprecherleistung und des Aufnahmeabstands besitzen die aufgenommenen Audiodateien eine niedrige Lautstärke. Vor dem späteren Modelltraining müssen die Audiosignale deshalb verstärkt werden. Zweitens enthalten die Aufnahmen unregelmäßige kurze Störgeräusche. Durch die getrennte Wiedergabe der einzelnen Kanäle wurde festgestellt, dass sich das Störgeräusch auf Kanal 10 konzentriert. Nach dem Stummschalten dieses Kanals war die Aufnahme wieder normal. Damit fehlerhafte Aufnahmen das Modelltraining nicht beeinflussen, muss das Signal von Kanal 10 vor dem Training entfernt werden. Die übrigen 15 Kanäle werden für das Training verwendet.

6.5 Zusammenfassung des Kapitels

Dieses Kapitel beschreibt die Vorbereitung der realen Datenerfassung und die während des Ablaufs aufgetretenen Probleme. Es erklärt die für diese Probleme vorgenommenen Verbesserungen des Steuerungssystems sowie die Vorteile und Mängel der endgültig erhaltenen Audiodaten.

7 Praktische Verwendung und Bewertung der Sprachdatenbank

7.1 Auswahl und kurze Beschreibung des Testalgorithmus

Der Testalgorithmus hat hauptsächlich die Aufgabe zu prüfen, ob ein Deep-Learning-Algorithmus die in diesem Versuch erstellte Sprachdatenbank richtig nutzen und die Sprachqualität und Sprachverständlichkeit verbessern kann. Besonders soll geprüft werden, ob die Positionslabels der Datenbank verwendet werden können, um die Modellgenauigkeit weiter zu erhöhen. Damit soll nachgewiesen werden, dass die Sprachdatenbank das Training zur Schallquellenfilterung bei Servicerobotern unterstützen kann. Zur Prüfung der wirksamen Nutzung der Positionslabels muss in diesem Versuch ein Algorithmus verwendet werden, der Richtungsinformationen der Schallquelle für das Training annehmen kann. Algorithmen, die Rauschen nur anhand akustischer Merkmale unterdrücken, zum Beispiel CleanUNet und FullSubNet, werden deshalb nicht betrachtet. Schließlich wird in diesem Versuch das Modell Spatially Selective Filter auf Grundlage des Joint Non-linear Filter, kurz JNF-SSF, verwendet. Dieses Modell nutzt gemeinsam die räumlichen Informationen und die Zeit-Frequenz-Informationen der Mehrkanalsignale und verwendet die Richtung der Zielschallquelle als Bedingung. Dadurch wird eine richtungsselektive Sprachverbesserung erreicht (Tesch et al.) [19].

7.2 Konfiguration von JNF-SSF und Vorverarbeitung der Audiodatenbank

Wie in Abschnitt 6.4 beschrieben, müssen die Audiodaten der Datenbank vor ihrer formellen Verwendung teilweise vorverarbeitet werden. Unter Berücksichtigung der Anforderungen des JNF-SSF-Algorithmus an die Modelleingabe wurden die folgenden Einstellungen und Verarbeitungen für JNF-SSF und die Audiodatenbank vorgenommen.

7.2.1 Definition der Richtungslabels

JNF-SSF erwartet als Eingabe den relativen Winkel der menschlichen Zielsprache zum Mikrofonarray. Da in der Datenbank die absoluten Winkel der einzelnen Bauteile relativ zum Boden gespeichert werden, müssen diese Winkel umgerechnet werden. Nach der Zusammenführung ergeben sich 13 relative Zielrichtungen. Zu beachten ist, dass der Algorithmus unterscheidet, ob sich die menschliche Zielstimme links oder rechts vom Mikrofonarray befindet. In diesem Versuch steht + für eine menschliche Stimme auf der linken Seite und - für eine menschliche Stimme auf der rechten Seite.

7.2.2 Ausrichtung der Audiodaten mit und ohne Störgeräusch

JNF-SSF benötigt ein Audio ohne Störgeräusch, das dieselben Positionsinformationen, dieselbe Nachhallumgebung und dieselben Aufnahmebedingungen besitzt, als Referenzaudio für das überwachte Training. Deshalb können Audiodateien mit und ohne Störgeräusch an derselben Position einander zugeordnet und als Trainingsdaten verwendet werden. Da die Aufnahme mit Störgeräusch und die Aufnahme ohne Störgeräusch jedoch in zwei getrennten Wiedergabe- und Aufnahmevorgängen erstellt wurden, kann am Anfang der Aufnahmen eine Verschiebung von einigen Millisekunden bis zu mehr als zehn Millisekunden vorhanden sein. Wenn beide Aufnahmen direkt für ein punktweises überwachtes Training verwendet werden, verursacht die kleine zeitliche Verschiebung eine Fehlausrichtung und verringert die Trainingsgenauigkeit. Deshalb ruft dieser Versuch eine vorhandene Funktion auf Grundlage von GCC-PHAT auf. Sie sucht in einem Bereich von ±2 s nach ähnlichen Signalformen in beiden Aufnahmen, um die Zeitverzögerung zwischen der gestörten und der sauberen Aufnahme zu schätzen.

7.2.3 Vorverarbeitung der Audiosignale

Wie in Abschnitt 6.4 beschrieben, besitzen die Audiodaten der Datenbank eine geringe Signalstärke, und Kanal 10 enthält ein Störgeräusch und muss entfernt werden. Gleichzeitig verlangt das JNF-SSF-Modell eine Eingabe mit einer Abtastrate von 16 kHz, während die ursprünglichen Aufnahmen mit 48 kHz erstellt wurden.

Deshalb müssen die Audiodaten zusätzlich neu abgetastet werden.

7.2.4 Trainingseinstellungen von JNF-SSF

Damit die Stimme derselben sprechenden Person nicht gleichzeitig im Trainings- und im Testdatensatz vorhanden ist, werden die Daten nach sprechenden Personen und nicht zufällig nach Aufnahmedateien aufgeteilt. Das endgültige Verhältnis der Anzahl sprechender Personen im Trainings-, Validierungs- und Testdatensatz beträgt 6: 1: 1. Beim Training wird Adam als Optimierer verwendet, die Batchgröße beträgt 6 und es werden 100 Trainingsepochen durchgeführt. Die endgültige Trainingsverlustkurve ist in Abbildung 13 dargestellt.

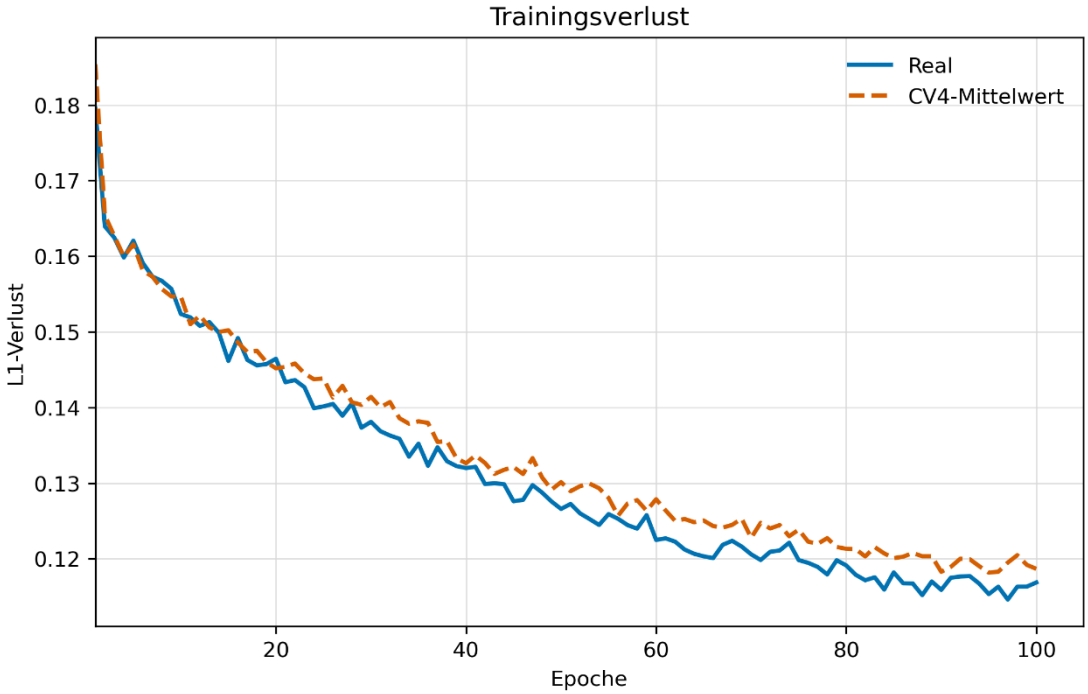


Abbildung 13: Trainingsverlustkurve

Zusammenfassend zeigt Abbildung 14 den endgültigen Ablauf des gesamten Softwaresteuerungssystems.

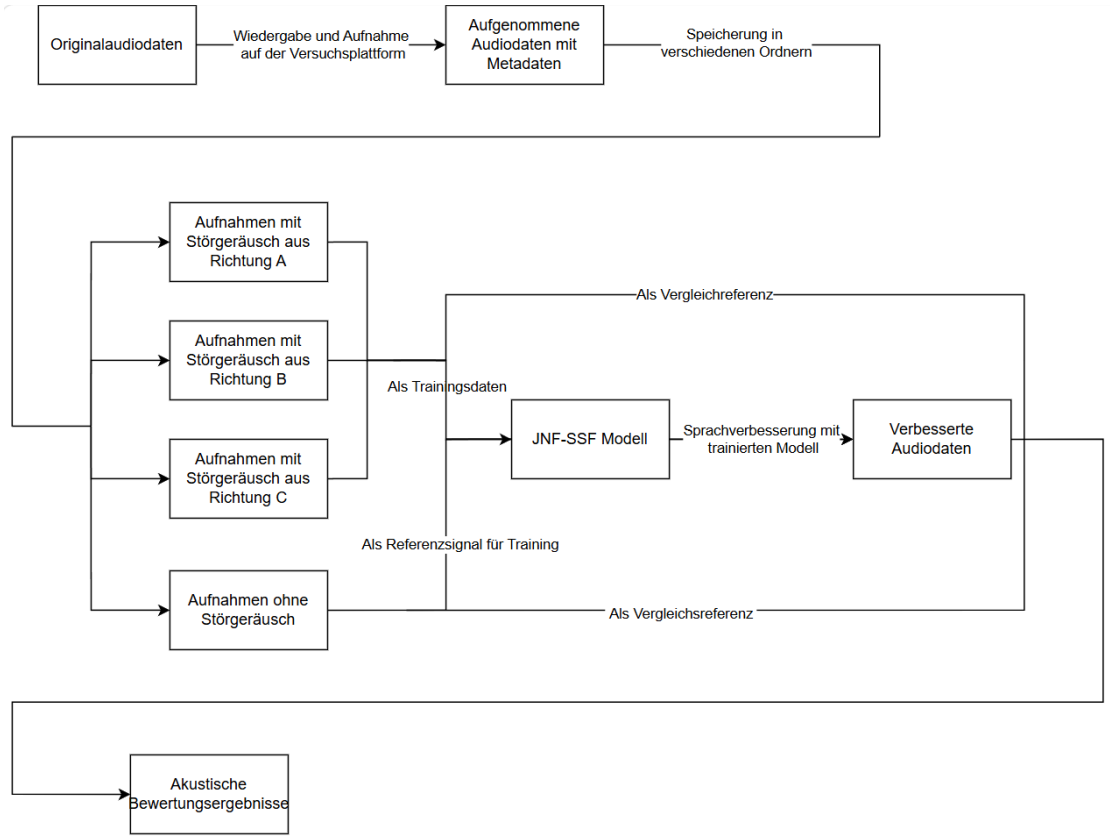


Abbildung 14: Steuerungsablauf des Softwaresystems

7.3 Trainings- und Bewertungsergebnisse

Es muss betont werden, dass die akustische Bewertung der vom Testalgorithmus gefilterten und verarbeiteten Audiodaten nicht hauptsächlich die Wirksamkeit des Algorithmus bei der Schallquellenfilterung nachweisen soll. Sie soll zeigen, dass diese Sprachdatenbank ein wirksames Modell zur Schallquellenfilterung trainieren kann. Daher sind die absoluten Werte der akustischen Bewertungskennwerte nicht entscheidend; wichtig sind die Veränderungen der Kennwerte unter unterschiedlichen Trainingsbedingungen.

7.3.1 Bewertung der Qualität der aufgenommenen Audiodaten

Während der Audioaufnahme verändert sich die Qualität der Audiodaten im Vergleich zum ursprünglichen Material. Abbildung 15 zeigt die akustischen Bewertungsdaten, die mit dem ursprünglichen LibriSpeech-Material als Referenzaudio und den aufgenommenen rauschfreien Audiodaten als zu prüfenden Audiodaten erhalten wurden. Es ist anzumerken, dass SNR die durch die

Vorverarbeitung der Audiodaten verursachte Erhöhung der Signalstärke nicht berücksichtigt. Daher wurde SI-SDR, bei dem die Skalierung automatisch angepasst wird, anstelle von SNR verwendet, um den Einfluss der Signalstärke auf die Beurteilung des Signal-Rausch-Verhältnisses zu vermeiden. Es ist zu erkennen, dass der SI-SDR der aufgenommenen Audiodaten -9,53 dB, PESQ 1,22 und STOI 0,80 betrug. Dies zeigt, dass die Qualität der aufgenommenen Audiodaten aufgrund von Faktoren wie der Hardware und dem Nachhall im Raum abgenommen hat.

Um zu verhindern, dass eine durch Probleme wie das Aufnahmegerät verursachte Verschlechterung der Audioqualität die Bewertungsdaten beeinflusst, wurden bei allen folgenden Bewertungen der akustischen Kennwerte die aufgenommenen rauschfreien Audiodaten als Referenzaudio verwendet.

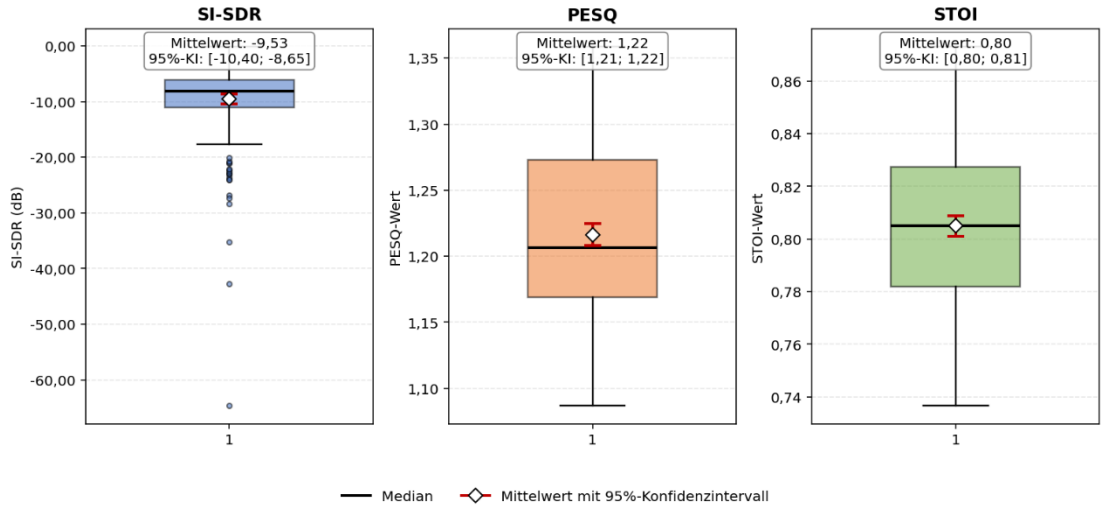


Abbildung 15: Bewertungskennwerte der aufgenommenen rauschfreien Audiodaten

7.3.2 Bewertung der Qualität der mit DAS verbesserten Audiodaten

Um eine Referenz für die später trainierten verbesserten Sprachdaten bereitzustellen, wurden in diesem Versuch zunächst die aufgenommenen verrauschten Audiodaten mit DAS verbessert. Die Bewertungsergebnisse sind in Abbildung 16 dargestellt. Es ist zu erkennen, dass die SI-SDR-Differenz der mit DAS verbesserten Audiodaten gegenüber den unverarbeiteten Audiodaten -0,71 betrug (95%-Konfidenzintervall: [-0,82, -0,66]), die PESQ-Differenz -0,04 betrug (95%-

Konfidenzintervall: [-0,05, -0,02]) und die STOI-Differenz -0,009 betrug (95%-Konfidenzintervall: [-0,010, -0,008]). Da der verwendete DAS-Algorithmus keine Positionslabel nutzte, wurde zur weiteren Untersuchung, ob die Positionslabel das Endergebnis beeinflussen, das DAS-Modul von SpeechBrain, einem quelloffenen All-in-One-Toolkit für Sprachverarbeitung, getestet [20]. Dieses Modul zeichnet sich dadurch aus, dass der Algorithmus die Eingabe von Positionslabeln zur Unterstützung der Audioverbesserung ermöglicht. Die Testergebnisse unterschieden sich jedoch nicht wesentlich von denen des zuvor verwendeten DAS (Abbildung 16). Daher kann die unzureichende Verbesserungswirkung nicht auf konkrete Unterschiede zwischen den Algorithmen zurückgeführt werden. Ein möglicher Grund dafür, dass der DAS-Algorithmus die Audioqualität stattdessen verschlechterte, ist die relativ komplexe reale Aufnahmeumgebung, beispielsweise der Nachhall und die ähnlichen Winkel der beiden Schallquellen, mit denen DAS nicht gut umgehen kann.

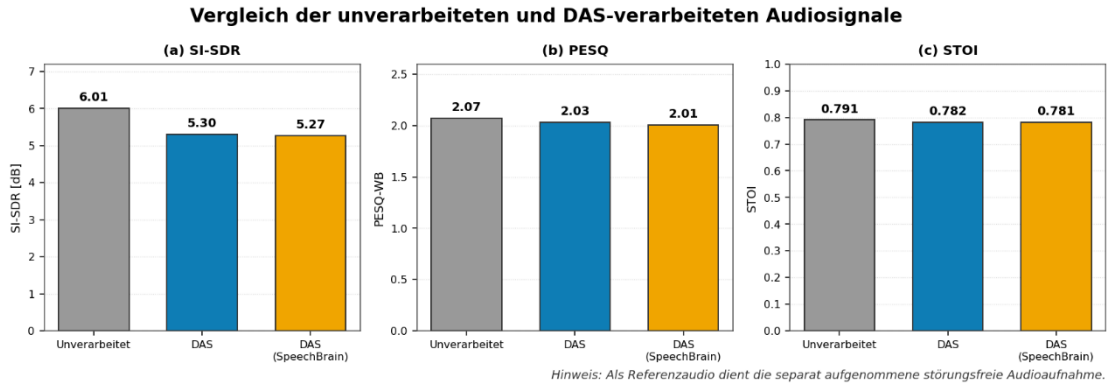


Abbildung 16: Bewertungskennwerte der DAS-Audiodaten

7.3.3 Bewertung der Qualität der mit JNF-SSF verbesserten Audiodaten

Nach Abschluss des JNF-SSF-Trainings wurde das Modell der 96. Epoche mit dem niedrigsten Verlustwert als endgültiges Modell ausgewählt. Die akustische Bewertung des Testdatensatzes ist in Abbildung 17 dargestellt. Wie Abbildung 17a zeigt, haben sich die akustischen Kennwerte der verbesserten Audiodaten im Vergleich zu den ursprünglichen Audiodaten deutlich verbessert. Der mittlere SI-SDR-, PESQ- und STOI-Wert stieg jeweils um 3,14 dB, 0,65 und 0,039. In diesem Experiment wurden die Sprachaufnahmen des Testdatensatzes zusätzlich jeweils mit

allen im Training verwendeten Richtungslabels versehen, getrennt verbessert und bewertet, um die Verbesserungsergebnisse des Testdatensatzes bei falschen Positionslabels zu untersuchen. Abbildung 17b zeigt, dass mit zunehmender Winkeldifferenz zwischen dem verwendeten falschen Label und dem ursprünglichen korrekten Label die SI-SDR-Ergebnisse mit den falschen Labels im Vergleich zu den Ergebnissen mit den korrekten Labels trotz einiger Schwankungen allmählich abnehmen. Die PESQ- und STOI-Ergebnisse zeigen nahezu vollständig einen abnehmenden Trend. Außerdem betrug bei allen erzeugten Bewertungsergebnissen der Anteil, bei dem das Ergebnis mit dem korrekten Label das beste Ergebnis war, 98,67 %. In Abbildung 17c wurden alle Positionslabels im Trainings- und Testdatensatz einheitlich auf 0° gesetzt. Dadurch verloren die Positionslabels ihre Unterscheidungsfähigkeit und halfen beim Training nicht. Die Ergebnisse zeigen, dass die Verbesserungsergebnisse mit Positionslabels etwas besser waren als ohne Positionslabels. Die mittleren Verbesserungen der drei Kennwerte betrugen 0,22 dB, 0,03 und 0,004. Keines der 95%-Konfidenzintervalle der oben genannten Daten enthielt 0. Daher können die Ergebnisse unter den Bedingungen dieses Versuchs als in gewissem Maße zuverlässig angesehen werden.

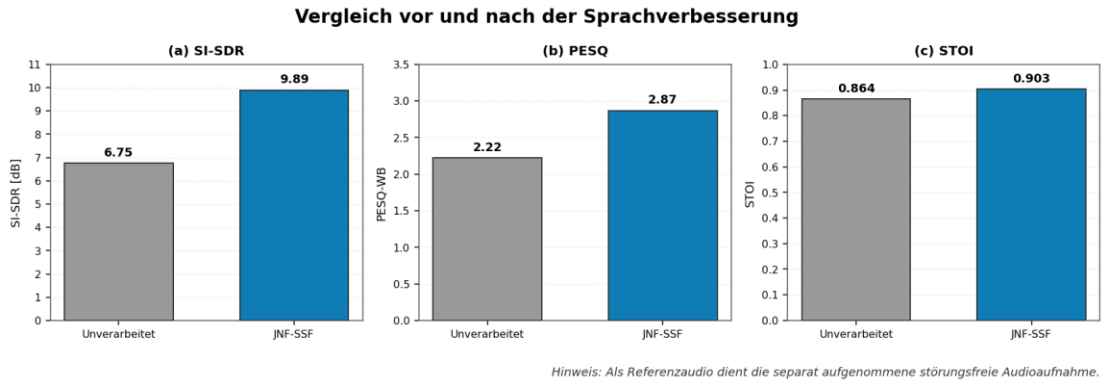


Abbildung 17a: Vergleich der Bewertung der ursprünglichen und der verbesserten Sprachaufnahmen

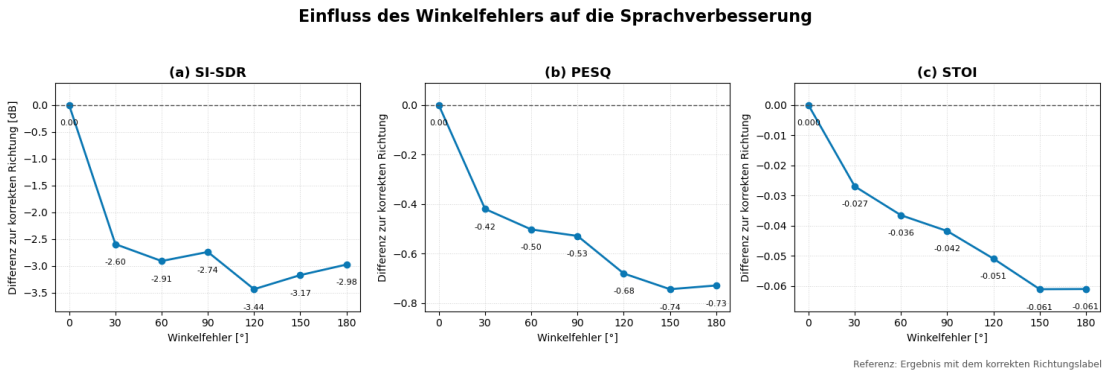


Abbildung 17b: Vergleich der Bewertung von Sprachaufnahmen mit richtigen und falschen Labels

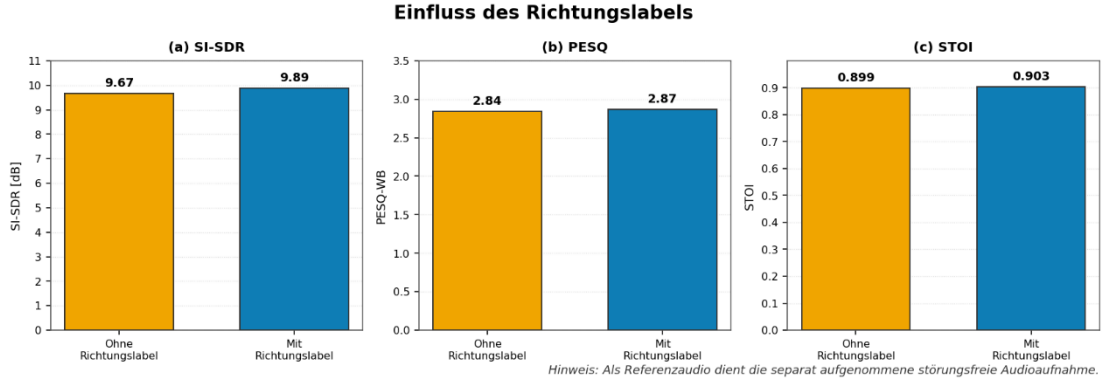


Abbildung 17c: Vergleich der Bewertung von Modellen ohne und mit Positionslabels

7.3.4 Bewertung der Qualität der durch das kreuzvalidiert trainierte Modell verbesserten Audiodaten

Bei der Transkription der Audiodaten vor und nach der Verbesserung mit dem Whisper-Spracherkennungsmodell large-v3 (Radford et al.) [21] und beim Vergleich der Wortfehlerrate (WER) der transkribierten Texte gegenüber dem Originaltext wurde festgestellt, dass die WER der verbesserten Audiodaten höher war als vor der Verbesserung. Die Ergebnisse betrugen jeweils 2,14 % und 1,36 %. Bei der Überprüfung wurde festgestellt, dass die mit Whisper erzielte Erkennungsrate der als Testdatensatz ausgewählten Audiodaten im Allgemeinen höher war als die der anderen Audiodaten. Wenn die WER der verrauschten Audiodaten bereits sehr niedrig ist, kann die Sprachverbesserung zudem keine deutliche Verbesserung des

Transkriptionsergebnisses bewirken. Die WER nach der Verbesserung ist wahrscheinlich fast gleich wie die ursprüngliche WER oder sogar etwas höher.

Um die Generalisierungsfähigkeit des JNF-SSF-Modells gegenüber nicht gesehenen Sprechern zu bewerten, wurde in diesem Versuch eine nach Sprechern gruppierte Vierfach-Kreuzvalidierung verwendet. Der vollständige Datensatz besteht aus 1.200 verrauschten Mehrkanalaufnahmen von acht Sprechern, wobei jeder Sprecher zwei verschiedene Sätze sprach. In jedem Fold wurden 750 Aufnahmen von fünf Sprechern für das Training, 150 Aufnahmen von einem Sprecher für die Validierung und 300 Aufnahmen von zwei weiteren Sprechern für den Test verwendet. In den vier Folds wurden vier unabhängige Modelle trainiert. Jedes Modell verarbeitete nur die beiden Testsprecher des jeweiligen Folds, die nicht am Training beteiligt waren. Jeder Sprecher trat in den vier Folds genau einmal als Testsprecher auf. Die vier Folds erzeugten insgesamt 1.200 verbesserte Out-of-Fold-Ergebnisse, die zur Berechnung von WER zusammengeführt wurden. Dadurch kann vermieden werden, dass Aufnahmen derselben Person gleichzeitig im Trainings- und Testdatensatz vorkommen. Auf diese Weise wird die durch Sprechermerkmale und wiederholte Sätze verursachte Datenleckage verringert.

Nach dem Training mit Kreuzvalidierung sind die Trainingsergebnisse der Audioverbesserung mit korrekten Positionslabels in Abbildung 18 dargestellt. Es ist zu erkennen, dass nach der Verwendung aller Audiodaten als Testdatensatz sämtliche WER-Werte in gewissem Maße stiegen, verglichen mit der vorherigen Verwendung nur eines Teils der Audiodaten als Testdatensatz. Die WER der rauschfreien Audiodaten betrug 4,94 %, die WER vor der Verbesserung 6,32 % und die WER nach der Verbesserung 5,26 %. Der Grund dafür ist, dass die durchschnittliche Erkennung der gesamten Audiodaten für Whisper schwieriger war als die des zuvor verwendeten Teils der Audiodaten. Nach der Verbesserung durch das kreuzvalidiert trainierte Modell war die WER der Audiodaten niedriger als vor der Verbesserung. Dies zeigt, dass JNF-SSF die Spracherkennungsrate wirksam erhöhen kann.

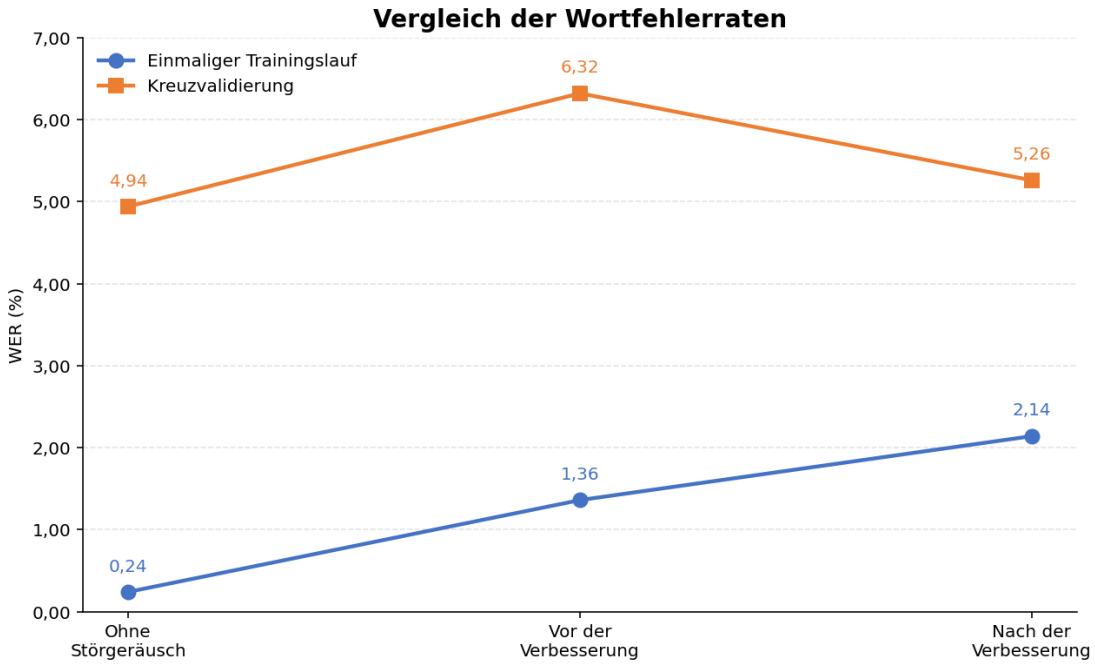


Abbildung 18: Vergleich der WER der Audiodaten vor und nach der Verbesserung bei einmaligem Training und Training mit Kreuzvalidierung

7.4 Zusammenfassung des Kapitels

Dieses Kapitel beschreibt, wie die fertig erfasste Sprachdatenbank für das Modelltraining verwendet wird. Nach der Konfiguration des Algorithmus, der Sprachvorverarbeitung, dem Modelltraining und der Bewertung des Testdatensatzes wurden die Ergebnisse der einzelnen akustischen Bewertungskennwerte bestimmt. Die Ergebnisse zeigen, dass die Sprachqualität nach der akustischen Filterung höher ist als vor der Filterung.

8 Diskussion der Versuchsergebnisse

8.1 Erklärung der Versuchsergebnisse

Im Vergleich zu den unverarbeiteten verrauschten Audiodaten, wurden SI-SDR, PESQ und STOI der nach der Schallquellenfilterung erhaltenen Audiodaten deutlich verbessert, und bei der Vierfach-Kreuzvalidierung sank die WER. Dies zeigt, dass die verarbeiteten Audiodaten weniger Grundrauschen enthalten, klarer klingen und eine bessere Hörqualität besitzen. Außerdem wurde in diesem Versuch die Leistung des Modells bei falschen Labels überprüft. Die Ergebnisse zeigen, dass die Verbesserung der Audiodaten mit den korrekten Labels in den meisten Fällen besser war als die Verbesserung derselben Audiodaten mit falschen Labels. Je größer die Winkeldifferenz zwischen dem verwendeten falschen Label und dem korrekten Label war, desto schlechter wurden die Bewertungskennwerte insgesamt. Dies zeigt, dass das Modell die Positionslabels tatsächlich gelernt und genutzt hat. Der Test des Modells ohne Positionslabels zeigt, dass dieses Modell etwas schlechter als das Modell mit Labels abschneidet, der Unterschied jedoch nicht deutlich ist. Eine erste Erklärung dafür ist, dass die Audiodaten der Sprachdatenbank nur eine menschliche Stimme und ein Störgeräusch enthalten und das Ziel daher eindeutig ist. Deshalb kann das Modell ohne Positionslabels allein anhand der akustischen Unterschiede zwischen der menschlichen Stimme und dem Störgeräusch trainiert werden. In diesem Fall arbeitet das Modell eher wie ein richtungsunabhängiges Sprachverbesserungsmodell, das keine expliziten Positionsinformationen verwendet. Daher ist zu erwarten, dass das Modell die Audiodaten auch ohne Labels wirksam verbessern kann. Daher kann angenommen werden, dass die Audiodaten der Sprachdatenbank und ihre Positionslabels für das Training eines auf Deep Learning basierenden Beamforming-Modells verwendet werden können.

Hinsichtlich der Versuchsaufgaben erfüllte dieser Versuch alle zuvor genannten Anforderungen vollständig oder teilweise:

(1) Die Anforderungen an die Anordnung der Schallquellen wurden vollständig erfüllt. In diesem Versuch wurden zwei bewegliche Schallquellen eingesetzt. Der Abstand zwischen beiden Schallquellen und dem Mikrofonarray betrug 1,5 m und entsprach damit einer realen Situation.

(2) Die Anforderungen an die Nachhallbedingungen wurden teilweise erfüllt. In diesem Versuch wurden zwar Aufnahmen mit verschiedenen Winkeln zwischen dem Mikrofonarray und den Wänden durchgeführt, der Raum wurde jedoch nicht gewechselt, um die tatsächliche Raumgröße zu verändern. Daher waren die Veränderungen der Nachhallbedingungen nicht vollständig und weitere Audioaufnahmen sind erforderlich.

(3) Die Anforderungen an das Steuerungssystem wurden vollständig erfüllt. Die automatisierte Erfassungsplattform setzte in diesem Versuch den gesamten Aufnahmeablauf vollständig um. Dabei erfolgten die Bewegungen der Lautsprecher und des Mikrofonarrays sowie die Wiedergabe, die Aufnahme und die Datenübertragung automatisch.

(4) Die Anforderungen an die Sprachdatenbank wurden teilweise erfüllt. Die in diesem Versuch erstellte Datenbank enthält Aufnahmen an verschiedenen Positionen, mit verschiedenen menschlichen Stimmen, mit unterschiedlicher Sprachdauer und unter verschiedenen Nachhallbedingungen. Für jede Aufnahme wurden notwendige Informationen wie die entsprechende Position in den Metadaten gespeichert. Die Datenbank enthält jedoch noch keine Aufnahmen mit verschiedenen Geräuschen und deckt nur einen engen Bereich von Nachhallbedingungen ab.

8.2 Fehleranalyse

8.2.1 Fehlerquellen

Die Fehler im gesamten Erfassungsablauf lassen sich hauptsächlich in zwei Arten unterteilen: Fehler der räumlichen Labels und Fehler der mechanischen Bewegung. Unter den verschiedenen Fehlerquellen haben die folgenden Punkte einen relativ großen Einfluss:

(1) Fehler des Drehzentrums. Bei der theoretischen Berechnung liegt das Drehzentrum des Lautsprechers im geometrischen Mittelpunkt des Mikrofonarrays. Der Drehwinkel der Motorwelle kann deshalb direkt dem Winkel des Lautsprechers relativ zum Mikrofonarray gleichgesetzt werden, und das Winkellabel des Lautsprechers in der Sprachdatenbank besitzt denselben Wert. In der Realität ist das Drehzentrum des Lautsprechers jedoch der Schrittmotor. Der Schrittmotor befindet sich an einer Ecke der zentralen Grundplatte und besitzt deshalb einen horizontalen Positionsabstand zum Mikrofonarray in der Mitte. Nach einer Messung beträgt dieser Abstand etwa 0,15 m. Da der mögliche Bewegungswinkel des Wagens 180° beträgt, ergibt eine mathematische Berechnung, dass sich die Abweichung zwischen dem gekennzeichneten und dem tatsächlichen Lautsprecherwinkel während der gesamten Bewegung zwischen 0° und 4° verändert. Dies ist die größte Fehlerquelle.

(2) Bewegungsfehler des Wagens. Um den Einfluss der Biegung des Schwenkarms auf das System zu verringern, wurde ein möglichst dicker Schwenkarm ausgewählt. Wegen der Werkstoffeigenschaften lässt sich eine Biegung des Schwenkarms jedoch nicht vollständig vermeiden. Dadurch entsteht am Ende des Schwenkarms nahe dem Wagen eine bestimmte Durchbiegung. Nach der Formel:

$$\delta = \frac{\mathrm{FL}^3}{3\mathrm{EI}} \tag{8.1}$$

Nach den praktischen Messungen lässt sich die Durchbiegung relativ genau bestimmen. Die gemessene mittlere Gesamtreibungskraft zwischen Wagen und Boden beträgt F = 1,5 N, die Stangenlänge L = 1,5 m, der Elastizitätsmodul der Aluminiumstange $E = 6{,}9 \times 10^{10}$ Pa und $I = 4{,}91 \times 10^{-10}$ m⁴. Daraus ergibt sich $\delta \approx 0{,}05$ m. Mit trigonometrischen Funktionen ergibt sich ein Abweichungswinkel von ungefähr 2°. Während der wiederholten Hin- und Herbewegung des Schrittmotors entstehen außerdem durch Abweichungen der einzelnen Wellenbewegungen, kleine Spiele bei der Montage der Übertragungsteile und ähnliche Ursachen Fehler in der endgültigen Position des Wagens. Der Einfluss dieser Abweichungen auf die Winkellabel wird ungefähr auf 0° bis 0,5° geschätzt.

(3) Fehler des Neigungswinkels des Lautsprechers. Beim Entwurf befinden sich

Lautsprecher und Mikrofonarray theoretisch auf derselben Höhe. Um die Aufnahmequalität möglichst weit zu erhöhen, muss die Schallöffnung des Lautsprechers jedoch höher als die Leiterplatte des Mikrofonarrays liegen, damit die Leiterplatte nicht einen Teil des Schallsignals blockiert und dadurch die Lautstärke der Mikrofonaufnahme verringert. Außerdem besitzt die Schallöffnung des Lautsprechers einen realen Radius und ist keine Punktschallquelle. Bei der praktischen Berechnung wird der Mittelpunkt der Lautsprecheröffnung als Punktschallquelle angenähert und anhand dieses Punkts der Höhenunterschied zwischen Lautsprecher und Mikrofonarray bestimmt. Unter Berücksichtigung dieser Faktoren ergibt die Berechnung, dass der tatsächliche Höhenwinkel der Schallquelle im Vergleich zum Labelwinkel leicht nach oben verschoben ist, ungefähr um 3°.

Unter Berücksichtigung aller genannten Faktoren liegen die Fehler der einzelnen Labels meistens im Bereich von 2° bis 4° und können im ungünstigsten Fall 6° erreichen. Da in der Datenbank in Abständen von jeweils 30° aufgenommen wird, beträgt die Abweichung zwischen Label und realem Winkel für eine Audiogruppe mit demselben Abstand ungefähr 6 % bis 13 %. Für ein Deep-Learning-Modell kann diese kleine Abweichung als Datenstörung betrachtet werden, deren Einfluss auf das Ergebnis in einem akzeptablen Bereich liegt.

8.2.2 Möglichkeiten für spätere Verbesserungen

In späteren Untersuchungen können diese Abweichungen verbessert werden. Beim Fehler des Drehzentrums können der Abstand zwischen Motor und Mikrofonarray sowie die Winkel zwischen beiden Bauteilen und dem Rand der Grundplatte vorher gemessen werden. Zusammen mit dem Drehwinkel der Motorwelle kann daraus eine Gleichung für den tatsächlichen Lautsprecherwinkel in Abhängigkeit vom Wellenwinkel aufgestellt werden. Beim Eintragen des Winkellabels wird der Zielwinkel aus dem Steuerungsprogramm in diese Gleichung eingesetzt. Der erhaltene Winkel ist dann der Drehwinkel ohne den Fehler des Drehzentrums. Beim Fehler durch die Biegeverformung der Stange können entsprechend geschätzte Werte wie die Reibungskraft eingesetzt werden, um einen

Näherungswert der Durchbiegung zu erhalten. Die daraus entstehende Abweichung kann mit trigonometrischen Funktionen berechnet werden. Entsprechend kann auch der Fehler des Neigungswinkels des Lautsprechers behandelt werden. Abweichungen durch reale Montagefehler und nicht ideale Umgebungsbedingungen lassen sich nur schwer beseitigen und sollen als zufällige Störungen betrachtet werden. Im Idealfall kann der Fehler der Winkellabel schließlich auf 1° bis 2° verringert werden. Dies entspricht 3 % bis 6 % eines Winkelabstands und ist für einen Deep-Learning-Algorithmus besser geeignet.

9 Zusammenfassung und Ausblick

9.1 Zusammenfassung der Versuchsarbeiten

Diese Arbeit beschreibt den Entwurf und Aufbau einer automatisierten Erfassungsplattform für eine Sprachdatenbank. Mit der fertig erfassten Sprachdatenbank wird außerdem ein Test zur Schallquellenfilterung mit einem Deep-Learning-Beamforming-Algorithmus durchgeführt. Ausgehend vom Lösungskonzept beschreibt der Versuch ausführlich die wichtigsten Schritte und zu beachtenden Punkte der Anforderungsanalyse, des Entwurfs der mechanischen Struktur, der Beschaffung von Bauteilen, der Bearbeitung von Teilen, des Entwurfs der Steuerungslogik, des praktischen Plattformaufbaus, der Konfiguration des Testalgorithmus und der akustischen Bewertung. Abschließend zeigen die akustischen Bewertungskennwerte, dass die Sprachdatenbank für das Training eines Modells zur Schallquellenfilterung verwendet werden kann.

9.2 Beitrag des Versuchs

In diesem Versuch wurde eine einfach aufgebaute, kostengünstige und wiederverwendbare Erfassungsplattform für eine Sprachdatenbank entworfen und umgesetzt. Sie verbessert die bisher unzureichende Verfügbarkeit von Sprachdatenbanken mit Positionslabels der Schallquellen für die Arbeitssituationen von Servicerobotern und bietet eine methodische Referenz sowie Lösungen für praktische Probleme beim späteren Aufbau einer Erfassungsplattform für Sprachdatenbanken.

9.3 Grenzen des Versuchs und mögliche Verbesserungen

Wegen der Versuchsbedingungen sowie der begrenzten Zeit und Geräte besitzt dieser Versuch weiterhin einige Einschränkungen. Erstens ist die Aufnahmeumgebung des Versuchs begrenzt. Wegen des Bewegungsbereichs der Erfassungsplattform und der Kabelanforderungen kann der Versuch weder in einem zu kleinen Raum noch im

Freien ohne Stromversorgung durchgeführt werden. Zweitens ist die Vielfalt des Sprach- und Geräuschmaterials nicht ausreichend. Wegen der begrenzten Zeit wurden im Versuch nur Mischaufnahmen aus 16 Sprachaufnahmen und einem Geräuschmaterial sowie saubere Aufnahmen dieser 16 Sprachaufnahmen erfasst. Außerdem nutzte der in diesem Versuch verwendete Validierungsalgorithmus die Winkelinformationen des Geräusches relativ zum Mikrofonarray nicht. Die Wirksamkeit dieser Informationen kann mit anderen Algorithmen überprüft werden. Drittens besitzen die Bauteile des Versuchs keine ausreichende Genauigkeit. Die Positioniergenauigkeit der Motoren, mechanische Montagefehler und Mängel der Mikrofonaufnahme beeinflussen die Genauigkeit der Positionslabels und die Aufnahmequalität des Endergebnisses. In späteren Untersuchungen kann der Versuch durch eine Erweiterung der Versuchsbedingungen, die Aufnahme weiteren Audiomaterials und eine höhere Genauigkeit der Aufnahmegeräte verbessert werden.

Literaturverzeichnis

[1] Jingjing Xu, Aaron Hsiao, Sacha Reid, Emily Ma, Working with service robots? A systematic literature review of hospitality employees' perspectives, International Journal of Hospitality Management, Volume 113, 2023, 103523, ISSN 0278-4319.

[2] El-Said, Osman, and Sara Al Hajri. "Are customers happy with robot service? Investigating satisfaction with robot service restaurants during the COVID-19 pandemic." Heliyon 8.3 (2022).

[3] Kim, Euihyun & Nakadai, Kazuhiro & Okuno, Hiroshi. (2014). Improved sound source localization in horizontal plane for binaural robot audition. Applied Intelligence. 42. 63-74. 10.1007/s10489-014-0544-y.

[4] Benesty, Jacob, and Chen Jingdong. Study and design of differential microphone arrays. Vol. 6. Springer Science & Business Media, 2012.

[5] McCowan, Iain. "Microphone arrays: A tutorial." Queensland University, Australia (2001): 1-38.

[6] Rascon, C. A Corpus-Based Evaluation of Beamforming Techniques and Phase-Based Frequency Masking. Sensors 2021, 21, 5005.

[7] Licitra, G., Artuso, F., Bernardini, M. et al. Acoustic Beamforming Algorithms and Their Applications in Environmental Noise. Curr Pollution Rep 9, 486–509 (2023).

[8] S. Y. Lee, J. Chang and S. Lee, "Deep Learning-Enabled High-Resolution and Fast Sound Source Localization in Spherical Microphone Array System," in IEEE Transactions on Instrumentation and Measurement, vol. 71, pp. 1-12, 2022.

[9] M. Kolbæk, Z. -H. Tan and J. Jensen, "On the Relationship Between Short-Time Objective Intelligibility and Short-Time Spectral-Amplitude Mean-Square Error for Speech Enhancement," in IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 27, no. 2, pp. 283-295, Feb. 2019.

[10] C. H. Taal, R. C. Hendriks, R. Heusdens and J. Jensen, "An Algorithm for Intelligibility Prediction of Time–Frequency Weighted Noisy Speech," in IEEE Transactions on Audio, Speech, and Language Processing, vol. 19, no. 7, pp. 2125-2136, Sept. 2011.

[11] Yang, Bing, et al. "RealMAN: A real-recorded and annotated microphone array dataset for dynamic speech enhancement and localization." Advances in Neural Information Processing Systems 37 (2024): 105997-106019.

[12] Evers, Christine, et al. "The LOCATA challenge: Acoustic source localization and tracking." IEEE/ACM Transactions on Audio, Speech, and Language Processing 28 (2020): 1620-1643.

[13] Kujawski, Adam, Art JR Pelling, and Ennes Sarradj. "MIRACLE—a microphone array impulse response dataset for acoustic learning." EURASIP Journal on Audio, Speech, and Music Processing 2024.1 (2024): 32.

[14] Jansson, Viktoria. "A literature study of rolling resistance and its affecting factors." (2022).

[15] Arrizabalaga, Jon, et al. "A caster-wheel-aware MPC-based motion planner for mobile robotics." 2021 20th International Conference on Advanced Robotics (ICAR). IEEE, 2021.

[16] Prashant Kumar, D.K. Sarkar, Sharad Chandra Gupta, Rolling resistance of elastic wheels on flat surfaces, Wear, Volume 126, Issue 2, 1988.

[17] V. Panayotov, G. Chen, D. Povey and S. Khudanpur, Librispeech An ASR corpus based on public domain audio books, 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), South Brisbane, QLD, Australia, 2015, pp. 5206-5210

[18] Thiemann, Joachim, Nobutaka Ito, and Emmanuel Vincent. "The diverse environments multi-channel acoustic noise database (demand): A database of multichannel environmental noise recordings." Proceedings of Meetings on Acoustics. Vol. 19. No. 1. Acoustical Society of America, 2013.

[19] Tesch, Kristina, and Timo Gerkmann. "Spatially selective deep non-linear filters for speaker extraction." ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.

[20] Ravanelli, Mirco, et al. "Open-source conversational ai with speechbrain 1.0." Journal of Machine Learning Research 25.333 (2024): 1-11.

[21] Radford, Alec, et al. "Robust speech recognition via large-scale weak supervision." *International conference on machine learning*. PMLR, 2023.

Anhang

1. Metadatenstruktur

Ein Beispiel für die vollständige Struktur der Metadaten ist in Abbildung 19 dargestellt.

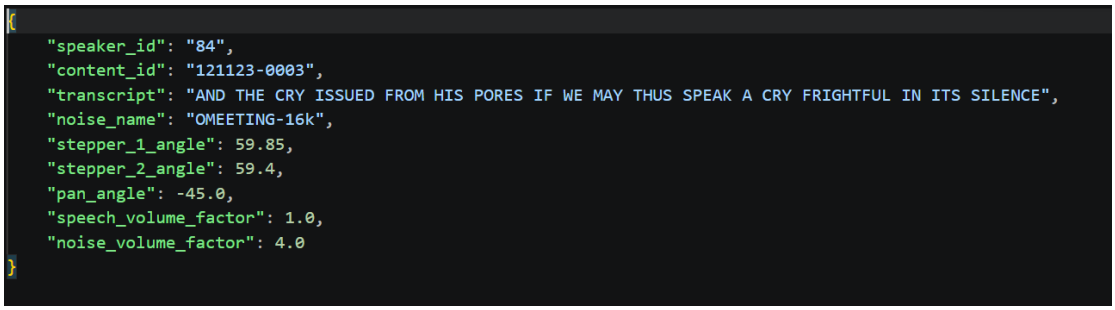


Abbildung 19: Beispiel für die Metadatenstruktur einer einzelnen Audiodatei

2. Liste der verwendeten Bauteile

Die auf der Versuchsplattform verwendeten Bauteile und eine Beschreibung einiger ihrer Funktionen sind in Tabelle 2 aufgeführt.

Central part		
	Description	Purpose
Microphone array	UMA-16	
Raspberry Pi		Controls loudsp., mic and motor
Loudspeaker cable		Between 2 loudspeakers
Loudspeaker cable	3.5 mm male to RCA	Raspberry Pi to loudspeaker
Power cable		Loudspeaker
Cable Duct		
Stepper motor	2x, 1 axis, 3 Nm	
Stepper Motor Holders	2x	
Shaft holder SH8/SK8	4x	
Mounting Hub	2x	

Metal rod	2x	Loudspeaker rotate
Triangle bracket	4x	
Pan-tilt Motor	2 axis	
Loudspeaker		
Loudspeaker	1 pair	
Base plate	4x, 250 x 250 mm; 1x, 300 x 300 mm	
Wheels	6x	
Tools and components		
Drill(woods)	8mm drill bit	
Screws	Schrauber: 8xM3, 8xM4, 8xM5, 32xM6; Holzschraube: 8xM4; Mutter: M4, M5, M6; Unterlegscheibe: M3, M4, M5, M6	

Tabelle 2: Übersicht der im Versuch verwendeten Bauteile